



دانشکده مهندسی برق

پروژه نهایی

دانشجوها:

نیلوفر ملا 40122903

محدثه علیرضایی طهرانی 40121123

استاد درس:

جناب آقای دکتر علیاری

لينك مخزن گيتهاب:

<https://github.com/m24ath/Smart-System>

لينك گوگل كولب:

<https://colab.research.google.com/drive/1wRNlhhatYIFIjMRaCVWneBHbcJYTO22fX?usp=sharing>

بِسْمِ اللّٰهِ الرَّحْمٰنِ الرَّحِيْمِ

عنوان پروژه

پیش‌بینی ریزش مشتریان مخابرات با یادگیری ماشین

(Telecom Customer Churn Prediction with Machine Learning)

فهرست مطالب

2.....	فهرست مطالب
3.....	فصل 1- مقدمه
4.....	فصل 2- هدف پژوهش
5.....	فصل 3- Dataset
6.....	فصل 4- بخش اول
11.....	فصل 5- بخش دوم
24.....	فصل 6- بخش سوم
30.....	فصل 7- بخش چهارم
35.....	فصل 8- بخش پنجم
54.....	فصل 9- بخش ششم
58.....	فصل 10- بخش هفتم
75.....	فصل 11- نتیجه گیری

فصل 1 - مقدمه

در بسیاری از کسبوکارهای مبتنی بر اشتراک، بهویژه در صنعت مخابرات، ریزش مشتری (Customer Churn) یکی از مهم‌ترین عوامل کاهش درآمد و افزایش هزینه‌های عملیاتی است. از آنجا که جذب یک مشتری جدید معمولاً هزینه‌برتر از نگهداشت مشتری فعلی است، توانایی پیش‌بینی احتمال ریزش و شناسایی مشتریان پریسک می‌تواند به تصمیم‌گیری‌های بهینه در زمینه‌ی بازاریابی، ارائه‌ی مشوق‌ها و تخصیص منابع پشتیبانی منجر شود. در این پژوهه، هدف طراحی و ارزیابی یک سامانه‌ی پیش‌بینی ریزش مشتری بر پایه‌ی داده‌های رفتاری و قراردادهای مشتریان است.

برای این منظور از دیتاست استاندارد Telco Customer Churn استفاده می‌شود که شامل ویژگی‌هایی از جنس عددی و دسته‌ای (مانند مدت زمان عضویت، هزینه‌های ماهله و کل، نوع قرارداد، روش پرداخت و سرویس‌های فعال و یک برچسب دودویی به نام Churn ریزش/عدم ریزش است. به دلیل ماهیت واقعی داده‌ها، انجام پیش‌پردازش‌هایی نظیر مدیریت مقادیر نامعتبر یا گمشده، کدگذاری ویژگی‌های دسته‌ای، مقیاس‌بندی متغیرهای عددی و بررسی عدم توازن کلاس‌ها نقش کلیدی در کیفیت مدل نهایی دارد. بنابراین، پژوهه صرفاً به آموزش یک مدل محدود نمی‌شود و بر ساخت یک خط لوله‌ی کامل یادگیری ماشین از مرحله‌ی آماده‌سازی داده تا تحلیل نتایج تمرکز دارد.

در ادامه، چندین سناریویی پیش‌پردازشی طراحی و اثر آن‌ها بر عملکرد مدل‌ها بررسی می‌شود. همچنین با توجه به افزایش تعداد ویژگی‌ها پس از تبدیل متغیرهای دسته‌ای به نمایش عددی مانند One-Hot Encoding، تکنیک‌های کاهش بُعد از جمله PCA و/یا روش‌های مشابه به کار گرفته شده و اثر کاهش بُعد بر دقت پیش‌بینی و هزینه‌ی محاسباتی تحلیل می‌شود. در بخش مدل‌سازی، حداقل دو الگوریتم یادگیری برای مثال SVM و درخت تصمیم آموزش داده شده و با تنظیم هایپرپارامترها، بهترین پیکربندی هر مدل استخراج می‌گردد. ارزیابی نهایی با استفاده از معیارهایی نظیر ROC-AUC و F1-score، Precision، Recall و نیز نمودارهایی مانند ROC Curve و Confusion Matrix انجام می‌شود تا هم عملکرد پیش‌بینی و هم رفتار خطاهای به صورت دقیق تفسیر شود. هدف نهایی، ارائه‌ی مدلی تکرارپذیر و قابل تحلیل است که بتواند مشتریان در معرض ریزش را با دقت مناسب شناسایی کند و مبنایی برای تصمیم‌گیری داده‌محور در مدیریت ارتباط با مشتری فراهم آورد.

فصل 2 - هدف پروژه

هدف اصلی (Prediction) —

ساخت یک مدل طبقه‌بندی که با استفاده از اطلاعات مشتری (قرارداد، سرویس‌ها، پرداخت، هزینه‌ها و ...) پیش‌بینی کند آیا مشتری ریزش می‌کند (Churn=Yes) یا نه (یا احتمال ریزش را بدهد).

هدف تحلیلی (Understanding) —

مشخص کنیم کدام الگوها/ویژگی‌ها بیشترین ارتباط را با ریزش دارند (مثلاً نوع قرارداد، مدت عضویت، هزینه‌ها، سرویس‌های جانبی).

هدف مهندسی (Pipeline & Report) —

پیاده‌سازی و مقایسه‌ی یک خط لوله‌ی کامل شامل:

- چند سناریوی پیش‌پردازش
- کاهش بُعد و بررسی اثرش روی دقت و هزینه محاسباتی
- آموزش حداقل دو مدل مثلاً SVM و درخت تصمیم Hyperparameter tuning
- ارزیابی استاندارد با معیارها و نمودارها + تکرار پذیری با Seedly

Dataset -3

این دیتاست یک نمونه‌ی استاندارد از داده‌های اشتراکی یا مخابراتی است (به صورت رایج منتشر شده توسط IBM و همچنین نسخه‌ی قابل دانلود آن در Kaggle موجود است). هر ردیف نماینده‌ی یک مشتری است و هدف، پیش‌بینی ستون Churn است.

ساختار داده

- واحد مشاهده: یک مشتری
- ستون هدف (Yes/No) : Churn
- ستون شناسه customerID : معمولا در مدل حذف می‌شود
- ویژگی‌های عددی مهم: tenure, MonthlyCharges, TotalCharges
- ویژگی‌های دسته‌ای (Categorical) (Mehm): Contract, PaymentMethod, InternetService, OnlineSecurity, TechSupport, PaperlessBilling, ...

لینک دیتاست

<https://drive.google.com/file/d/17MsXa86Pe778yn63Z9KDMd9qZfiwpLVQ/view?usp=sharing>

که آن را از گیتهاب دانلود کردیم

فصل 4 - بخش اول

۱. معرفی مسئله و داده‌ها:

- معرفی دقیق مجموعه داده انتخاب شده (منبع، تعداد ویژگی‌ها، تعداد نمونه‌ها، توزیع کلاس‌ها و ...).
- در صورت انتخاب «هوشمندسازی سیستم»، توصیف دقیق عملکرد سیستم و نحوه جمع‌آوری داده‌ها.

در این قسمت با استفاده کدهای لازم اطلاعات مربوط به دیتابیس را نمایش می‌دهیم.

```
#1
!pip -q install gdown

import os
import io
import pandas as pd

GDRIVE_URL =
"https://drive.google.com/file/d/17MsXa86Pe778yn63Z9KDMd9qZfiwpLVQ/view?usp=sharing"

CSV_PATH = "WA_Fn-UseC_-Telco-Customer-Churn.csv"

!gdown --fuzzy "{GDRIVE_URL}" -O "{CSV_PATH}"

df = pd.read_csv(CSV_PATH)

print("\n===== BASIC SHAPE =====")
print("Rows (samples):", df.shape[0])
print("Columns (all):", df.shape[1])

target_col = "Churn" if "Churn" in df.columns else None
if target_col is not None:
    print("Target column:", target_col)
    print("Features (excluding target):", df.shape[1] - 1)
else:
    print("Target column 'Churn' not found. Features (all columns):",
df.shape[1])

print("\n===== COLUMNS =====")
print(list(df.columns))

print("\n===== DATA.INFO() =====")
buf = io.StringIO()
```

```

df.info(buf=buf)
print(buf.getvalue())

print("\n===== MISSING VALUES (NaN) =====")
na_counts = df.isna().sum().sort_values(ascending=False)
na_nonzero = na_counts[na_counts > 0]
print(na_nonzero if len(na_nonzero) else "No NaN values found.")

print("\n===== BLANK/EMPTY STRINGS (OBJECT COLUMNS) =====")
obj_cols = df.select_dtypes(include=["object"]).columns
blank_counts = {}
for c in obj_cols:
    blank_counts[c] = df[c].astype(str).str.strip().eq("").sum()
blank_series = pd.Series(blank_counts).sort_values(ascending=False)
blank_nonzero = blank_series[blank_series > 0]
print(blank_nonzero if len(blank_nonzero) else "No blank strings found in object columns.")

if target_col is not None:
    print("\n===== CLASS DISTRIBUTION (Churn) =====")
    class_counts = df[target_col].value_counts(dropna=False)
    class_percent = (class_counts / len(df) * 100).round(2)
    class_dist = pd.DataFrame({"count": class_counts, "percent": class_percent})
    print(class_dist)

display(df.head())

```

خروجی

```

===== BASIC SHAPE =====
Rows (samples): 7043
Columns (all): 21
Target column: Churn
Features (excluding target): 20

===== COLUMNS =====
['customerID', 'gender', 'SeniorCitizen', 'Partner', 'Dependents', 'tenure',
'PhoneService', 'MultipleLines', 'InternetService', 'OnlineSecurity',
'OnlineBackup', 'DeviceProtection', 'TechSupport', 'StreamingTV',
'StreamingMovies', 'Contract', 'PaperlessBilling', 'PaymentMethod',
'MonthlyCharges', 'TotalCharges', 'Churn']

===== DATA.INFO() =====
<class 'pandas.core.frame.DataFrame'>

```

RangeIndex: 7043 entries, 0 to 7042
Data columns (total 21 columns):

#	Column	Non-Null Count	Dtype
0	customerID	7043 non-null	object
1	gender	7043 non-null	object
2	SeniorCitizen	7043 non-null	int64
3	Partner	7043 non-null	object
4	Dependents	7043 non-null	object
5	tenure	7043 non-null	int64
6	PhoneService	7043 non-null	object
7	MultipleLines	7043 non-null	object
8	InternetService	7043 non-null	object
9	OnlineSecurity	7043 non-null	object
10	OnlineBackup	7043 non-null	object
11	DeviceProtection	7043 non-null	object
12	TechSupport	7043 non-null	object
13	StreamingTV	7043 non-null	object
14	StreamingMovies	7043 non-null	object
15	Contract	7043 non-null	object
16	PaperlessBilling	7043 non-null	object
17	PaymentMethod	7043 non-null	object
18	MonthlyCharges	7043 non-null	float64
19	TotalCharges	7043 non-null	object
20	Churn	7043 non-null	object

dtypes: float64(1), int64(2), object(18)
memory usage: 1.1+ MB

===== MISSING VALUES (NaN) =====
No NaN values found.

===== BLANK/EMPTY STRINGS (OBJECT COLUMNS) =====
TotalCharges 11
dtype: int64

===== CLASS DISTRIBUTION (Churn) =====
count percent
Churn

	count	percent
No	5174	73.46
Yes	1869	26.54

	customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	
0	7590-VHVEG	Female	0	Yes	No	1	No	No	No phone service
1	5575-GNVDE	Male	0	No	No	34	Yes	No	
2	3668-QPYBK	Male	0	No	No	2	Yes	No	
3	7795-CFOCW	Male	0	No	No	45	No	No	No phone service
4	9237-HQITU	Female	0	No	No	2	Yes	No	

	customerID	InternetService	OnlineSecurity	...	DeviceProtection	TechSupport	StreamingTV
0	7590-VHVEG	DSL	No	...	No	No	No
1	5575-GNVDE	DSL	Yes	...	Yes	No	No
2	3668-QPYBK	DSL	Yes	...	No	No	No
3	7795-CFOCW	DSL	Yes	...	Yes	Yes	No
4	9237-HQITU	Fiber optic	No	...	No	No	No

	StreamingMovies	Contract	PaperlessBilling	PaymentMethod	MonthlyCharges	TotalCharges	Churn
0	No	Month-to-month	Yes	Electronic check	29.85	29.85	No
1	No	One year	No	Mailed check	56.95	1889.5	No
2	No	Month-to-month	Yes	Mailed check	53.85	108.15	Yes
3	No	One year	No	Bank transfer (automatic)	42.30	1840.75	No
4	No	Month-to-month	Yes	Electronic check	70.70	151.65	Yes

ابعاد دیتاست

تعداد نمونه‌ها (Rows): 7043

تعداد ستون‌ها: 21

ستون هدف: Churn

تعداد ویژگی‌ها (بدون هدف): 20

نوع داده‌ها (Data Types) و پیامدها

:info() طبق

MonthlyCharges: فقط 1 ستون float64

SeniorCitizen و tenure: 2 ستون int64

18 ستون يعني عدتاً متنی هستند: object

این دیتاست Logistic ، SVM categorical-heavy است. پس برای اکثر مدل‌های کلاسیک مثل Regression حتماً باید:

انجام شود معمولاً One-Hot Encoding. و برای مدل‌هایی مثل SVM باید Scaling

وضعیت داده‌های گمشده

خروجی نشان می‌دهد:

No NaN values found.

اما هم‌زمان در بخش TotalCharges، Blank Strings 11 مقدار خالی وجود دارد. یعنی داده‌ی گمشده داریم، ولی به شکل " ذخیره شده، نه NaN برای همین isna() چیزی پیدا نکرده است.

از طرفی TotalCharges باید عددی باشد، ولی الان object است. دلیلش همین مقادیر خالی (و گاهی رشته‌ای بودن) است.

باشد TotalCharges را تبدیل به numeric کنیم (با errors='coerce' تا خالی‌ها NaN شوند) بعد تصمیم بگیریم 11 ردیف را حذف کنیم یا ایمپوت کنیم مثلًا با میانه یا رابطه‌ی MonthlyCharge × tenure.

توزيع کلاس‌ها

خروجی:

No : 5174 (73.46%)

Yes: 1869 (26.54%)

این یک عدم توازن متوسط است (نه خیلی شدید، نه کاملاً بالائنس).

فصل 5 - بخش دوم

۲. پیش‌پردازش داده‌ها (Data Preprocessing)

- اعمال روش‌های مختلف پیش‌پردازش (مانند مدیریت داده‌های گم شده، نرمال‌سازی، استانداردسازی، مدیریت داده‌های پرت و ...).
- تحلیل اثر: بررسی و نمایش تاثیر هر یک از روش‌های پیش‌پردازش بر روی توزیع داده‌ها و نتایج نهایی.

در این بخش، هدف ما ساختن یک پایپلاین پیش‌پردازش برای دیتاست ریزش مشتریان است و سپس مقایسه‌ی چند سناریوی مختلف پیش‌پردازش است. ابتدا ستون‌های غیرضروری مثل customerID حذف می‌شوند. سپس ستون TotalCharges که باید عددی باشد، از حالت متغیر خارج شده و مقادیر خالی آن به NaN تبدیل می‌گردد. طبق خروجی قبلی، تعداد این مقادیر بسیار کم است (حدود 11 رکورد)، بنابراین به جای تبدیل می‌گردد. سطرهای دارای مقدار گمشده حذف می‌شوند تا کیفیت داده حفظ شود و تحلیل ساده‌تر و قابل دفعاتر باشد.

بعد از آن، چون دیتاست شامل ویژگی‌های دسته‌ای (غیرعددی) زیادی است، این ویژگی‌ها با روش One-Hot Encoding به نمایش عددی بدون ایجاد ترتیب مصنوعی تبدیل می‌شوند. در نهایت برای ویژگی‌های عددی، چند روش مختلف مقیاس‌بندی را به عنوان سناریوهای متفاوت امتحان می‌کنیم و با ثابت نگه داشتن یک مدل ساده (Logistic Regression)، اثر هر سناریو را روی معیارهای عملکرد Accuracy، F1، ROC-AUC، ... و بر توزیع داده‌ها مقایسه می‌کنیم. سناریوی برتر در مراحل بعدی پروژه استفاده خواهد شد.

```
#2
import os
import numpy as np
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, MinMaxScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, precision_score, recall_score,
f1_score, roc_auc_score

# -----
# Common preprocessing (ALL scenarios)
# -----
# Drop useless ID
if "customerID" in df.columns:
    df = df.drop(columns=["customerID"])
```

```
# Fix TotalCharges (blank -> NaN -> numeric)
df["TotalCharges"] = df["TotalCharges"].astype(str).str.strip()
df.loc[df["TotalCharges"].eq(""), "TotalCharges"] = np.nan
df["TotalCharges"] = pd.to_numeric(df["TotalCharges"], errors="coerce")

# Missing handling: drop rows with NaN (only 11 rows)
before_rows = len(df)
df = df.dropna().copy()
after_rows = len(df)

print("Missing handling:")
print("Rows before:", before_rows, "| Rows after:", after_rows, "|"
Dropped:, before_rows - after_rows)

y = df["Churn"].map({"Yes": 1, "No": 0})
X = df.drop(columns=["Churn"])

num_cols = ["tenure", "MonthlyCharges", "TotalCharges"]

cat_cols = [c for c in X.columns if c not in num_cols]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

def print_categorical_distributions(X_df, categorical_columns):
    print("\n" + "="*70)
    print("Categorical distributions BEFORE any preprocessing (TRAIN)")
    print("=".*70)
    for col in categorical_columns:
        vc = X_df[col].value_counts(dropna=False)
        vp = (vc / len(X_df) * 100).round(2)
        dist = pd.DataFrame({"count": vc, "percent": vp})
        print(f"\n--- {col} ---")
        print(dist.to_string())

print_categorical_distributions(X_train, cat_cols)
print("\nNumeric distribution BEFORE any scaling (TRAIN):")
print(X_train[num_cols].describe().T[["mean", "std", "min", "max"]])

# -----
# Helper functions
# -----
def one_hot_align(train_df, test_df):
```

```

tr = pd.get_dummies(train_df, drop_first=False)
te = pd.get_dummies(test_df, drop_first=False)
tr, te = tr.align(te, join="left", axis=1, fill_value=0)
return tr, te

def iqr_clip(train_df, test_df, cols):
    tr = train_df.copy()
    te = test_df.copy()
    bounds = {}

    for c in cols:
        q1 = tr[c].quantile(0.25)
        q3 = tr[c].quantile(0.75)
        iqr = q3 - q1
        low = q1 - 1.5 * iqr
        high = q3 + 1.5 * iqr
        bounds[c] = (low, high)

        tr[c] = tr[c].clip(low, high)
        te[c] = te[c].clip(low, high)

    return tr, te, bounds

def scale_numeric(train_df, test_df, cols, method):
    tr = train_df.copy()
    te = test_df.copy()

    if method == "standard":
        scaler = StandardScaler()
    elif method == "minmax":
        scaler = MinMaxScaler()
    else:
        raise ValueError("method must be 'standard' or 'minmax'")

    tr[cols] = scaler.fit_transform(tr[cols])
    te[cols] = scaler.transform(te[cols])

    return tr, te

def evaluate_model(Xtr, Xte, ytr, yte):
    model = LogisticRegression(max_iter=3000, solver="liblinear",
                               random_state=42)
    model.fit(Xtr, ytr)

    pred = model.predict(Xte)

```

```
prob = model.predict_proba(Xte)[:, 1]

return {
    "accuracy": accuracy_score(yte, pred),
    "precision": precision_score(yte, pred, zero_division=0),
    "recall": recall_score(yte, pred, zero_division=0),
    "f1": f1_score(yte, pred, zero_division=0),
    "roc_auc": roc_auc_score(yte, prob),
}

def run_scenario(name, scale_method, use_outliers):
    tr = X_train.copy()
    te = X_test.copy()

    # Outlier handling
    bounds = None
    if use_outliers:
        tr, te, bounds = iqr_clip(tr, te, num_cols)

    # Scaling
    tr, te = scale_numeric(tr, te, num_cols, scale_method)

    # One-hot encoding
    tr_enc, te_enc = one_hot_align(tr, te)

    # Distribution AFTER preprocessing (numeric only)
    num_dist = tr[num_cols].describe().T[["mean", "std", "min", "max"]]

    # One-hot distribution idea: show top 10 most frequent binary features
    cat_features = [c for c in tr_enc.columns if c not in num_cols]
    top10 =
    (tr_enc[cat_features].mean().sort_values(ascending=False).head(10) * 100)

    metrics = evaluate_model(tr_enc, te_enc, y_train, y_test)

    print("\n" + "="*65)
    print("Scenario:", name)
    if bounds is not None:
        print("\nOutlier bounds (computed on TRAIN, IQR method):")
        for k, (lo, hi) in bounds.items():
            print(f"{k}: low={lo:.3f}, high={hi:.3f}")

    print("\nNumeric distribution AFTER preprocessing (TRAIN):")
    print(num_dist)
```

```

print("\nTop 10 most frequent one-hot features (TRAIN) [%]:")
print(top10.round(2).to_string())

print("\nModel performance (TEST):")
print(pd.DataFrame([metrics]).to_string(index=False))

return {"scenario": name, **metrics, "n_features_after_onehot":
tr_enc.shape[1]}
results = []
results.append(run_scenario("S1) Standardization",
scale_method="standard", use_outliers=False))
results.append(run_scenario("S2) Normalization", scale_method="minmax",
use_outliers=False))
results.append(run_scenario("S3) Outlier(IQR) + Standardization",
scale_method="standard", use_outliers=True))
results.append(run_scenario("S4) Outlier(IQR) + Normalization",
scale_method="minmax", use_outliers=True))

final_df = pd.DataFrame(results).sort_values("roc_auc", ascending=False)
print("\n" + "="*65)
print("FINAL COMPARISON (sorted by ROC-AUC):")
print(final_df.to_string(index=False))

```

ما دیتاست Telco را وارد کردیم، ستون بی ارزش customerID را حذف کردیم، ستون TotalCharges را حذف کردیم، که بعضی جاهای به صورت متن یا خالی بود به عدد تبدیل کردیم، سپس اگر داده گمشده‌ای باقی می‌ماند رده‌های دارای مقدار خالی را حذف می‌کردیم. بعد داده‌ها را به train و test تقسیم کردیم. قبل از هر پیش‌پردازش، توزیع ستون‌های غیر عددی را با تعداد و درصد هر دسته چاپ کردیم و همچنین آمار کلی ستون‌های عددی را نشان دادیم. سپس 4 سناریویی پیش‌پردازش ساختیم: استانداردسازی، نرمال‌سازی، مدیریت پرت با روش IQR همراه با استانداردسازی، و مدیریت پرت با روش IQR همراه با نرمال‌سازی. در هر سناریو، ستون‌های غیر عددی را با One-Hot به عددی تبدیل کردیم، توزیع عددی بعد از پیش‌پردازش و پرتکارترین ستون‌های One-Hot را چاپ کردیم و در نهایت با یک مدل ثابت Logistic Regression عملکرد هر سناریو را روی داده test مقایسه کردیم.

تبدیل به عدد TotalCharges

```
df["TotalCharges"] = df["TotalCharges"].astype(str).str.strip()  
df.loc[df["TotalCharges"].eq(""), "TotalCharges"] = np.nan  
df["TotalCharges"] = pd.to_numeric(df["TotalCharges"], errors="coerce")
```

اینجا فضاهای خالی به NaN تبدیل می‌شوند و بعد کل ستون عددی می‌شود.

تبدیل به دسته‌ای SeniorCitizen

```
df["SeniorCitizen"] = df["SeniorCitizen"].astype(str)
```

زیرا مفهومش دسته‌ای است، نه یک مقدار عددی پیوسته.

خروجی

Missing handling:

Rows before: 7032 | Rows after: 7032 | Dropped: 0

```
=====  
Categorical distributions BEFORE any preprocessing (TRAIN)  
=====
```

```
--- gender ---  
      count   percent  
gender  
Male      2823     50.19  
Female    2802     49.81
```

```
--- SeniorCitizen ---  
      count   percent  
SeniorCitizen  
0          4715     83.82  
1          910      16.18
```

```
--- Partner ---  
      count   percent  
Partner  
No        2891     51.4  
Yes       2734     48.6
```

```
--- Dependents ---  
      count   percent  
Dependents  
No        3940     70.04  
Yes       1685     29.96
```

```
--- PhoneService ---  
      count   percent  
PhoneService  
Yes       5080     90.31
```

No	545	9.69
--- MultipleLines ---		
	count	percent
MultipleLines		
No	2695	47.91
Yes	2385	42.40
No phone service	545	9.69
--- InternetService ---		
	count	percent
InternetService		
Fiber optic	2483	44.14
DSL	1934	34.38
No	1208	21.48
--- OnlineSecurity ---		
	count	percent
OnlineSecurity		
No	2803	49.83
Yes	1614	28.69
No internet service	1208	21.48
--- OnlineBackup ---		
	count	percent
OnlineBackup		
No	2446	43.48
Yes	1971	35.04
No internet service	1208	21.48
--- DeviceProtection ---		
	count	percent
DeviceProtection		
No	2473	43.96
Yes	1944	34.56
No internet service	1208	21.48
--- TechSupport ---		
	count	percent
TechSupport		
No	2759	49.05
Yes	1658	29.48
No internet service	1208	21.48
--- StreamingTV ---		
	count	percent
StreamingTV		
No	2229	39.63
Yes	2188	38.90
No internet service	1208	21.48
--- StreamingMovies ---		
	count	percent
StreamingMovies		
No	2222	39.50
Yes	2195	39.02
No internet service	1208	21.48

```
--- Contract ---
      count   percent
Contract
Month-to-month    3085     54.84
Two year          1358     24.14
One year          1182     21.01

--- PaperlessBilling ---
      count   percent
PaperlessBilling
Yes                 3349     59.54
No                  2276     40.46

--- PaymentMethod ---
      count   percent
PaymentMethod
Electronic check    1907     33.90
Mailed check        1268     22.54
Bank transfer (automatic) 1235     21.96
Credit card (automatic) 1215     21.60

Numeric distribution BEFORE any scaling (TRAIN):
      mean       std      min      max
tenure      32.562311  24.542421  1.0      72.00
MonthlyCharges 64.999316  30.108642  18.4     118.65
TotalCharges 2301.839520 2275.586084  18.8     8684.80
=====
Scenario: S1) Standardization

Numeric distribution AFTER preprocessing (TRAIN):
      mean       std      min      max
tenure      -1.291609e-16 1.000089 -1.286145  1.607062
MonthlyCharges 3.157968e-17 1.000089 -1.547843  1.782062
TotalCharges  8.842310e-18 1.000089 -1.003365  2.805224

Top 10 most frequent one-hot features (TRAIN) [%]:
PhoneService_Yes      90.31
Dependents_No          70.04
PaperlessBilling_Yes    59.54
Contract_Month-to-month 54.84
Partner_No              51.40
gender_Male             50.19
OnlineSecurity_No        49.83
gender_Female            49.81
TechSupport_No           49.05
Partner_Yes              48.60

Model performance (TEST):
accuracy  precision  recall      f1  roc_auc
0.803838  0.648485  0.572193  0.607955  0.835942
=====
Scenario: S2) Normalization

Numeric distribution AFTER preprocessing (TRAIN):
```

	mean	std	min	max
tenure	0.444540	0.345668	0.0	1.0
MonthlyCharges	0.464831	0.300336	0.0	1.0
TotalCharges	0.263448	0.262588	0.0	1.0

Top 10 most frequent one-hot features (TRAIN) [%]:

PhoneService_Yes	90.31
Dependents_No	70.04
PaperlessBilling_Yes	59.54
Contract_Month-to-month	54.84
Partner_No	51.40
gender_Male	50.19
OnlineSecurity_No	49.83
gender_Female	49.81
TechSupport_No	49.05
Partner_Yes	48.60

Model performance (TEST):

accuracy	precision	recall	f1	roc_auc
0.804549	0.651376	0.569519	0.607703	0.834751

Scenario: S3) Outlier(IQR) + Standardization

Outlier bounds (computed on TRAIN, IQR method):

tenure: low=-61.500, high=126.500
 MonthlyCharges: low=-45.575, high=171.425
 TotalCharges: low=-4670.050, high=8884.750

Numeric distribution AFTER preprocessing (TRAIN):

	mean	std	min	max
tenure	-1.291609e-16	1.000089	-1.286145	1.607062
MonthlyCharges	3.157968e-17	1.000089	-1.547843	1.782062
TotalCharges	8.842310e-18	1.000089	-1.003365	2.805224

Top 10 most frequent one-hot features (TRAIN) [%]:

PhoneService_Yes	90.31
Dependents_No	70.04
PaperlessBilling_Yes	59.54
Contract_Month-to-month	54.84
Partner_No	51.40
gender_Male	50.19
OnlineSecurity_No	49.83
gender_Female	49.81
TechSupport_No	49.05
Partner_Yes	48.60

Model performance (TEST):

accuracy	precision	recall	f1	roc_auc
0.803838	0.648485	0.572193	0.607955	0.835942

Scenario: S4) Outlier(IQR) + Normalization

Outlier bounds (computed on TRAIN, IQR method):

tenure: low=-61.500, high=126.500
 MonthlyCharges: low=-45.575, high=171.425

TotalCharges: low=-4670.050, high=8884.750

Numeric distribution AFTER preprocessing (TRAIN):

	mean	std	min	max
tenure	0.444540	0.345668	0.0	1.0
MonthlyCharges	0.464831	0.300336	0.0	1.0
TotalCharges	0.263448	0.262588	0.0	1.0

Top 10 most frequent one-hot features (TRAIN) [%]:

PhoneService_Yes	90.31
Dependents_No	70.04
PaperlessBilling_Yes	59.54
Contract_Month-to-month	54.84
Partner_No	51.40
gender_Male	50.19
OnlineSecurity_No	49.83
gender_Female	49.81
TechSupport_No	49.05
Partner_Yes	48.60

Model performance (TEST):

accuracy	precision	recall	f1	roc_auc
0.804549	0.651376	0.569519	0.607703	0.834751

FINAL COMPARISON (sorted by ROC-AUC):

roc_auc	n_features_after_onehot	scenario	accuracy	precision	recall	f1
0.835942	S1) Standardization	0.803838	0.648485	0.572193	0.607955	
	45					
0.835942	S3) Outlier(IQR) + Standardization	0.803838	0.648485	0.572193	0.607955	
	45					
0.834751	S2) Normalization	0.804549	0.651376	0.569519	0.607703	
	45					
0.834751	S4) Outlier(IQR) + Normalization	0.804549	0.651376	0.569519	0.607703	
	45					

توزیع غیر عددی ها قبل از پیش پردازش

gender کاملاً متعادل است تقریباً

Male حدود 50.19 درصد

Female حدود 49.81 درصد

SeniorCitizen نامتوازن است

0 حدود 83.82 درصد

1 حدود 16.18 درصد

Dependents هم نامتوازن است

درصد 70.04 حدود No

درصد 29.96 حدود Yes

PhoneService خیلی نامتوازن است

درصد 90.31 حدود Yes

درصد 9.69 حدود No

این یعنی بعضی دسته‌ها خیلی پر تکرارند و بعضی کم تکرار. تبدیل One-Hot توزیع دسته‌ها را تغییر نمی‌دهد، فقط شکل نمایش را عددی می‌کند.

توزیع عددی قبل از پیش‌پردازش

tenure

میانگین حدود 32.56

انحراف معیار حدود 24.54

کمینه 1 و بیشینه 72

MonthlyCharges

میانگین حدود 65

انحراف معیار حدود 30.11

کمینه 18.4 و بیشینه 118.65

TotalCharges

میانگین حدود 2301.84

انحراف معیار حدود 2275.59

کمینه 18.8 و بیشینه 8684.8

TotalCharges دامنه خیلی بزرگ‌تری نسبت به بقیه دارد، پس اگر مقیاس‌بندی انجام نشود ممکن است روی مدل‌های خطی اثر نامتوازن بگذارد. برای همین ساریوهای scaling منطقی هستند.

سناریو S1: استانداردسازی

اثر روی توزیع عددی

پس از اعمال StandardScaler، میانگین هر ستون عددی به حدود 0 و انحراف معیار به حدود 1 رسیده است. این یعنی داده‌های عددی هم مقیاس شده‌اند.

اثر روی One-Hot

در ویژگی‌های One-Hot، هیچ تغییری رخ نداده و درصدها کاملاً ثابت مانده است. برای مثال PhoneService_Yes همچنان 90.31٪ است. دلیل این است که scaling روی ستون‌های غیرعددی اعمال نمی‌شود.

عملکرد مدل

- accuracy = 0.803838

- f1 = 0.607955

-roc_auc = 0.835942

سناریو S2: نرمال‌سازی

اثر روی توزیع عددی

پس از اعمال MinMaxScaler، کمینه هر ستون عددی به 0 و بیشینه به 1 رسیده است. این یعنی داده‌های عددی در بازه [0,1] قرار گرفته‌اند.

عملکرد مدل

- accuracy = 0.804549

- f1 = 0.607703

- roc_auc = 0.834751

این دو سناریو عملکرد بسیار نزدیکی دارند، اما از نظر معیار ROC_AUC، سناریوی استانداردسازی (S1) نتیجه بهتری داده است.

سناریو S3: IQR پرت + استانداردسازی

نتایج نشان می‌دهد که مرزهای محاسبه شده برای شناسایی پرت‌ها بسیار بزرگتر از محدوده واقعی داده‌ها هستند.

Tenure - بازه پرت 61.5 - 126.5، در حالی که داده‌های واقعی بین 1 تا 72 هستند

MonthlyCharges - بازه پرت 45.575 - 171.425، در حالی که داده‌های واقعی بین 18.4 و 118.65 هستند

TotalCharges - بازه پرت 4670.05 - 8884.75، در حالی که داده‌های واقعی بین 18.8 و 8684.8 هستند

از آنجا که هیچ نقطه‌ای خارج از این بازه‌ها قرار نداشته، عمل clipping انجام نشده و مدیریت پرت عملاً هیچ تغییری در داده‌ها ایجاد نکرده است. به همین دلیل، توزیع داده‌های عددی و عملکرد مدل در این سناریو دقیقاً برابر با سناریوی S1 (استانداردسازی ساده) شده است.

سناریو S4: IQR پرت + نرمالسازی

دقیقاً همان اتفاق S3 تکرار شده است. از آنجا که داده‌ها هیچ مقدار پرتی خارج از بازه‌های محاسبه شده IQR نداشتند، عمل clipping هیچ تغییری در داده‌ها اعمال نکرده است. توزیع داده‌های عددی دقیقاً برابر با سناریوی S2 (نرمالسازی ساده) شده است عملکرد مدل نیز کاملاً مشابه S2 است بنابراین مدیریت پرت در این دیتاست عملاً تاثیری بر خروجی نداشته و نتایج دقیقاً مشابه حالت بدون مدیریت پرت است.

در نهایت بهترین مقدار ROC_AUC متعلق به سناریوهای S1 و S3 با مقدار 0.835942 است. اما از آنجا که در سناریوی S3 مرحله مدیریت پرت با روش IQR هیچ تغییری در داده‌ها ایجاد نکرده است، این مرحله عملاً بی‌اثر و اضافی محسوب می‌شود.

بنابراین بهترین سناریو برای ادامه پروژه سناریو S1 استانداردسازی (StandardScaler) به همراه پیش‌پردازش‌های مشترک ابتدایی است چرا که:

- بالاترین مقدار ROC_AUC را در بین سناریوهای دارد

- ساده‌تر و کم‌هزینه‌تر از S3 است

- مرحله مدیریت پرت با روش IQR در این دیتاست هیچ تغییری اعمال نکرده و افزودن آن تنها باعث پیچیدگی بی‌دلیل کد می‌شود.

فصل 6 - بخش سوم

۳. کاهش ابعاد (Dimensionality Reduction)

- پیاده‌سازی تکنیک‌های کاهش ابعاد (مانند PCA، LDA، t-SNE و ...).
- تحلیل اثر کاهش ابعاد بر روی دو فاکتور کلیدی: دقت مدل (Accuracy) و سرعت آموزش/استنتاج (Speed/Computational Cost).

در این قسمت ابتدا پیش پردازش‌های منتخب از قسمت قبل را مجدد روی دیتابست اصلی که قبلاً از آن کپی گرفته بودیم انجام می‌دهیم و سپس به سراغ کاهش ابعاد با استفاده از PCA, LDA t-SNE PCA می‌رویم.

```
#3
import numpy as np
import pandas as pd
from time import perf_counter

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score

from sklearn.decomposition import PCA
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
from sklearn.manifold import TSNE

if "customerID" in data.columns:
    data = data.drop(columns=["customerID"])

if "TotalCharges" in data.columns:
    data["TotalCharges"] = data["TotalCharges"].astype(str).str.strip()
    data.loc[data["TotalCharges"].eq(""), "TotalCharges"] = np.nan
    data["TotalCharges"] = pd.to_numeric(data["TotalCharges"],
                                         errors="coerce")

data = data.dropna().copy()

y = data["Churn"].map({"Yes": 1, "No": 0})
X = data.drop(columns=["Churn"])

X = pd.get_dummies(X, drop_first=False)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)
```

```
)  
  
def run_method(method_name):  
    t0 = perf_counter()  
  
    scaler = StandardScaler()  
    Xtr_s = scaler.fit_transform(X_train.values)  
    Xte_s = scaler.transform(X_test.values)  
  
    reducer = None  
  
    if method_name == "Baseline":  
        Xtr_r = Xtr_s  
        Xte_r = Xte_s  
  
    elif method_name == "PCA":  
        reducer = PCA(n_components=0.99, random_state=42)  
        Xtr_r = reducer.fit_transform(Xtr_s)  
        Xte_r = reducer.transform(Xte_s)  
  
    elif method_name == "LDA":  
        reducer = LinearDiscriminantAnalysis(n_components=1)  
        Xtr_r = reducer.fit_transform(Xtr_s, y_train.values)  
        Xte_r = reducer.transform(Xte_s)  
  
    elif method_name == "t-SNE":  
        reducer = TSNE(  
            n_components=2,  
            perplexity=30,  
            learning_rate="auto",  
            init="pca",  
            random_state=42  
        )  
        X_all = np.vstack([Xtr_s, Xte_s])  
        X_all_emb = reducer.fit_transform(X_all)  
        Xtr_r = X_all_emb[:len(X_train)]  
        Xte_r = X_all_emb[len(X_train):]  
  
    else:  
        raise ValueError("Unknown method")  
  
    model = LogisticRegression(max_iter=3000, solver="liblinear",  
random_state=42)  
    model.fit(Xtr_r, y_train.values)
```

```
fit_time = perf_counter() - t0

t1 = perf_counter()

if method_name in ["Baseline", "PCA", "LDA"]:
    Xte_s2 = scaler.transform(X_test.values)
    if method_name == "Baseline":
        Xte_final = Xte_s2
    elif method_name == "PCA":
        Xte_final = reducer.transform(Xte_s2)
    elif method_name == "LDA":
        Xte_final = reducer.transform(Xte_s2)

elif method_name == "t-SNE":
    Xte_final = Xte_r

proba = model.predict_proba(Xte_final)[:, 1]
pred = (proba >= 0.5).astype(int)

inference_time = perf_counter() - t1

acc = accuracy_score(y_test.values, pred)
f1 = f1_score(y_test.values, pred)
auc = roc_auc_score(y_test.values, proba)

return {
    "method": method_name,
    "n_features_after": int(Xtr_r.shape[1]),
    "fit_time_sec": float(fit_time),
    "inference_time_sec": float(inference_time),
    "accuracy": float(acc),
    "f1": float(f1),
    "roc_auc": float(auc),
}

results = []
for m in ["Baseline", "PCA", "LDA", "t-SNE"]:
    results.append(run_method(m))

results_df = pd.DataFrame(results).sort_values("roc_auc", ascending=False)

display(results_df)
```

ابتدا داده‌ها را بارگذاری کردیم، ستون `customerID` را حذف کردیم، ستون `TotalCharges` را به صورت رشته خالی بود به مقدار عددی تبدیل کردیم و سطرهای دارای مقدار گمشده را حذف کردیم. سپس متغیر هدف `Churn` را به ۰ و ۱ نگاشت کردیم و ویژگی‌های غیرعددی را با روش One-Hot Encoding به عددی تبدیل کردیم. بعد از هم‌تراز کردن ستون‌های `train` و `test`، همه ویژگی‌ها را با استانداردسازی کردیم. در ادامه چهار حالت را مقایسه کردیم: بدون کاهش بعد (`StandardScaler`)، کاهش بعد با `PCA`، کاهش بعد با `LDA` و کاهش بعد با `t-SNE` (Baseline). آموزش دادیم و معیارهای دقت و همچنین زمان آموزش و پیش‌بینی را اندازه‌گیری و مقایسه کردیم.

تابع `train_eval`

ابتدا مدل را آموزش می‌دهد (زمانش می‌شود `train_time_sec`) سپس روی داده `test` احتمال را حساب می‌کند و پیش‌بینی می‌کند (زمانش می‌شود `inference_time_sec`) در نهایت `f1`، `accuracy` و `roc_auc` را می‌دهد. در کد ما، فقط زمان `predict` مدل است نه زمان `inference_time_sec`.

خروجی

	<code>method</code>	<code>n_features_after</code>	<code>fit_time_sec</code>	<code>inference_time_sec</code>	<code>accuracy</code>	<code>f1</code>	<code>roc_auc</code>	
0	Baseline	45	0.135082		0.008615	0.803838	0.609065	0.835564
1	PCA	20	0.245199		0.020899	0.798152	0.600000	0.828757
2	LDA	1	0.228243		0.011977	0.794598	0.582973	0.828286
3	t-SNE	2	90.732185		0.000629	0.738451	0.361111	0.740901

اثر روی دقت مدل

بهترین دقت و بهترین ROC-AUC را دارد:

`accuracy` ≈ 0.8038

`roc_auc` ≈ 0.8356 (بهترین)

افت خیلی کم نسبت به baseline PCA

accuracy (0.0056 0.7982 ← 0.8038

roc_auc (0.0068 0.8288 ← 0.8356

یعنی PCA با نصف کردن ابعاد، هنوز عملکرد نسبتاً نزدیک نگه داشته است.

LDA چون فقط 1 به بعد را نگه می‌دارد، افتخار بیشتر حس می‌شود:

accuracy ≈ 0.7946

f1 (0.583) افت واضح‌تر دارد

t-SNE بدترین عملکرد را داده است:

accuracy ≈ 0.738

f1 ≈ 0.361 (خیلی پایین)

roc_auc ≈ 0.741 (خیلی پایین)

از نظر دقت به ترتیب Baseline > PCA ≈ LDA >> t-SNE

اثر روی سرعت آموزش

t-SNE از نظر زمان آموزش فاجعه‌است چرا که حدود 89 ثانیه طول کشیده است. دلیلش این است که SNE ذاتاً محاسباتی سنگین است.

بین سه تای دیگر

LDA سریع‌ترین fit_time را داده (0.141s)

Baseline دوم است (0.169s)

PCA کندر شده (0.263s) زیرا خود محاسبه fit_transform (PCA) هزینه دارد. روی

دیتاست‌های کوچک مثل دیت ست ما، هزینه PCA از سود کاهش بعد بیشتر می‌شود، برای همین fit_time بالا می‌رود.

اثر روی سرعت استنتاج

t-SNE inference خیلی کم شده (0.000464) چون فقط 2 ویژگی به مدل می‌رسد.

Baseline/PCA/LDA بین

Baseline: 0.0127

PCA: 0.0097 (کمی بهتر)

LDA: 0.0092 (کمی بهتر)

در نهایت بین تکنیک های کاهش ابعاد PCA از بقیه بهتر است.

فصل 7 - بخش چهارم

۴. انتخاب و آموزش مدل‌ها:

- انتخاب حداقل دو روش یادگیری (روش‌های کلاسیک مطرح شده در درس یا روش‌های پیشرفته‌تر مانند (Deep Learning).
- توجیه انتخاب مدل‌ها با توجه به نوع داده و مسئله.

در این قسمت بعد انجام PCA بر روی داده‌ها، اقدام به آموزش مدل با سه روش Logistic Regression و Decision Tree و SVM می‌کنیم.

```
#4
import numpy as np
import pandas as pd
from time import perf_counter

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

from sklearn.linear_model import LogisticRegression
from sklearn.svm import LinearSVC
from sklearn.tree import DecisionTreeClassifier

from sklearn.metrics import accuracy_score, f1_score, roc_auc_score

if "customerID" in data.columns:
    data = data.drop(columns=["customerID"])

if "TotalCharges" in data.columns:
    data["TotalCharges"] = data["TotalCharges"].astype(str).str.strip()
    data.loc[data["TotalCharges"].eq(""), "TotalCharges"] = np.nan
    data["TotalCharges"] = pd.to_numeric(data["TotalCharges"],
                                         errors="coerce")

if "SeniorCitizen" in data.columns:
    data["SeniorCitizen"] = data["SeniorCitizen"].astype(str)

data = data.dropna().copy()

y = data["Churn"].map({"Yes": 1, "No": 0})
X = data.drop(columns=["Churn"])
```

```

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

X_train_ohe = pd.get_dummies(X_train, drop_first=False)
X_test_ohe = pd.get_dummies(X_test, drop_first=False)
X_train_ohe, X_test_ohe = X_train_ohe.align(X_test_ohe, join="left",
axis=1, fill_value=0)

scaler = StandardScaler()
pca = PCA(n_components=0.99, random_state=42)

t0 = perf_counter()
Xtr_scaled = scaler.fit_transform(X_train_ohe)
Xtr_pca = pca.fit_transform(Xtr_scaled)
prep_fit_time = perf_counter() - t0

n_features_after = Xtr_pca.shape[1]
print("n_features_after (PCA):", n_features_after)

def eval_model(model_name, model):
    t0 = perf_counter()
    model.fit(Xtr_pca, y_train)
    model_fit_time = perf_counter() - t0

    t1 = perf_counter()
    Xte_scaled = scaler.transform(X_test_ohe)
    Xte_pca = pca.transform(Xte_scaled)

    if hasattr(model, "predict_proba"):
        scores = model.predict_proba(Xte_pca)[:, 1]
        pred = (scores >= 0.5).astype(int)
        roc_input = scores
    else:
        scores = model.decision_function(Xte_pca)
        pred = (scores >= 0).astype(int)
        roc_input = scores

    inference_time = perf_counter() - t1

    return {
        "model": model_name,
        "n_features_after": n_features_after,
        "fit_time_sec": prep_fit_time + model_fit_time,
        "inference_time_sec": inference_time,
    }

```

```
"accuracy": accuracy_score(y_test, pred),
"f1": f1_score(y_test, pred),
"roc_auc": roc_auc_score(y_test, roc_input),
}

results = []

lr = LogisticRegression(
    max_iter=3000,
    solver="liblinear",
    random_state=42,
    class_weight="balanced"
)
results.append(eval_model("LogisticRegression + PCA", lr))

svm = LinearSVC(
    random_state=42,
    class_weight="balanced"
)
results.append(eval_model("LinearSVM + PCA", svm))

dt = DecisionTreeClassifier(
    random_state=42,
    class_weight="balanced",
    max_depth=None
)
results.append(eval_model("DecisionTree + PCA", dt))

results_df = pd.DataFrame(results).sort_values("roc_auc", ascending=False)
display(results_df)
```

پس از اینکه با PCA ابعاد را طوری کم کردیم که اینجا شد 99% واریانس حفظ شود (که اینجا شد 20 ویژگی). در نهایت، روی داده‌ی کاهش بعديافتہ سه مدل Decision Tree و Linear SVM و Logistic Regression را آموختند. در اینجا در مورد Decision Tree بيشتر کد كه مشابه قسمت قبل است در انتهای تابع `eval_model` به هر مدل را نيز می نويسیم.

n_features_after (PCA): 20

	model	n_features_after	fit_time_sec	inference_time_sec	accuracy	f1	roc_auc
0	LogisticRegression + PCA	20	0.092831	0.025928	0.722814	0.600410	0.828198
1	LinearSVM + PCA	20	0.100689	0.016539	0.719972	0.600406	0.828014
2	DecisionTree + PCA	20	0.676485	0.015128	0.705046	0.460338	0.631290

کیفیت مدل‌ها

Linear SVM و Logistic Regression تقریباً برابرند

roc_auc هر دو حدود 0.828 خیلی نزدیک بهم

f1 هر دو حدود 0.60 یعنی قدرت تفکیک‌شان روی داده PCA شده تقریباً یکی است.

Decision Tree واضحًا ضعیف‌تر است:

roc_auc = 0.63 یعنی مدل خیلی بدتر تفکیک می‌کند

f1 = 0.46 یعنی در پیدا کردن churners ضعیف‌تر است

پس برای ادامه پروژه انتخاب خوبی نیست.

سرعت آموزش و استنتاج

زمان آموزش

LR \approx 0.093s

SVM \approx 0.101s

اختلاف خیلی کم است (عملاً هر دو سریع‌اند).

Decision Tree \approx 0.676s (خیلی بیشتر)

زمان پیش‌بینی

SVM و DecisionTree سریع‌تر از LR هستند.

LR کمی سریع‌تر از SVM و DecisionTree معمولاً چون predict_proba می‌دهد، ممکن است کمی کنترل‌راز decision_function باشد.

چرا این مدل‌ها را انتخاب کردیم؟

مسئله ما یک طبقه‌بندی دودویی برای پیش‌بینی ریزش مشتری (Churn Yes/No) است. داده‌ها به صورت جدولی و متشکل از ویژگی‌های عددی و دسته‌ای هستند. پس از اعمال One-Hot Encoding، تعداد ویژگی‌ها افزایش یافته و سپس با PCA به فضای پیوسته و فشرده کاهش بعد یافته‌اند.

Logistic Regression

به عنوان یک مدل کلاسیک و استاندارد برای طبقه‌بندی دودویی آن را انتخاب کردیم. این مدل روی ویژگی‌های استاندارد شده و به ویژه پس از کاهش بعد با PCA عملکرد بسیار خوبی دارد. خروجی احتمال (predict_proba) در این مدل، برای محاسبه ROC-AUC و تنظیم آستانه تصمیم‌گیری بسیار کاربردی است. علاوه بر این، سرعت بالا، پایداری و قابلیت گزارش‌پذیری از دیگر مزایای این مدل هستند.

SVM خطی

برای داده‌های با ابعاد نسبتاً بالا، حتی پس از کاهش بعد با PCA، گزینه مناسبی محسوب می‌شود. این مدل با داده‌های استاندارد شده به خوبی کار می‌کند و معمولاً قدرت تعمیم بالایی دارد. در بسیاری از مسائل، عملکرد SVM خطی به Logistic Regression نزدیک است و از نظر سرعت در مرحله Inference نیز کارآمد است.

Decision Tree

این مدل به دلیل قابلیت تفسیرپذیری شناخته می‌شود، اما پس از اعمال PCA، ویژگی‌ها ترکیب خطی از ویژگی‌های اصلی هستند و معنای مستقیم خود را از دست می‌دهند. در نتیجه، هم از نظر تفسیرپذیری و هم از نظر عملکرد، درخت تصمیم افت محسوسی دارد که خروجی مدل نیز این کاهش عملکرد را تأیید کرده است.

فصل 8 - بخش پنجم

۵. تنظیم هایپرپارامترها (Hyperparameter Tuning)

- استفاده از روش‌های جستجوی نظاممند مانند Random Search، Grid Search یا کتابخانه‌های بهینه‌سازی مانند Optuna.
- گزارش دقیق تمام هایپرپارامترهای جستجو شده و مقادیر بهینه نهایی.

```
#5
!pip -q install optuna
from sklearn.model_selection import StratifiedKFold, GridSearchCV,
RandomizedSearchCV, cross_val_score
import optuna
from optuna.samplers import TPESampler
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

def save_cv_results(cv_results, filename):
    df2 = pd.DataFrame(cv_results)[["mean_test_score", "std_test_score",
"rank_test_score", "params"]]
    df2 = df2.sort_values("rank_test_score")
    df2.to_csv(filename, index=False)
    print("Saved:", filename, "| rows:", len(df2))

def build_model(model_key, params):
    if model_key == "LogisticRegression":
        m = LogisticRegression(max_iter=3000, solver="liblinear",
random_state=42)
    elif model_key == "LinearSVM":
        m = LinearSVC(random_state=42, max_iter=5000)
    elif model_key == "DecisionTree":
        m = DecisionTreeClassifier(random_state=42)
    else:
        raise ValueError("Unknown model key")

    m.set_params(**params)
    return m

grid_spaces = {
    "LogisticRegression": {
        "C": [0.01, 0.1, 1, 10, 100],
        "penalty": ["l1", "l2"],
        "class_weight": [None, "balanced"]
    },
}
```

```
"LinearSVM": {
    "C": [0.01, 0.1, 1, 10, 100],
    "class_weight": [None, "balanced"]
},
"DecisionTree": {
    "criterion": ["gini", "entropy"],
    "max_depth": [None, 5, 10],
    "min_samples_split": [2, 10],
    "min_samples_leaf": [1, 5],
    "class_weight": [None, "balanced"]
}
}

random_spaces = {
    "LogisticRegression": {
        "C": list(np.logspace(-3, 2, 25)),
        "penalty": ["l1", "l2"],
        "class_weight": [None, "balanced"]
    },
    "LinearSVM": {
        "C": list(np.logspace(-3, 2, 25)),
        "class_weight": [None, "balanced"]
    },
    "DecisionTree": {
        "criterion": ["gini", "entropy"],
        "max_depth": [None, 3, 5, 8, 12],
        "min_samples_split": [2, 5, 10, 20, 40],
        "min_samples_leaf": [1, 2, 5, 10, 20],
        "class_weight": [None, "balanced"]
    }
}

models_base = {
    "LogisticRegression": LogisticRegression(max_iter=3000,
solver="liblinear", random_state=42),
    "LinearSVM": LinearSVC(random_state=42, max_iter=5000),
    "DecisionTree": DecisionTreeClassifier(random_state=42)
}

best_summary = []
final_models_results = []

for model_key in ["LogisticRegression", "LinearSVM", "DecisionTree"]:
    print("\n" + "="*80)
```

```

print("TUNING MODEL:", model_key)
print("="*80)

# ----- GRID SEARCH -----
print("\nGRID SEARCH SPACE:")
for k, v in grid_spaces[model_key].items():
    print(k, "->", v)

gs = GridSearchCV(
    estimator=models_base[model_key],
    param_grid=grid_spaces[model_key],
    scoring="roc_auc",
    cv=cv,
    n_jobs=-1,
    refit=True
)

t0 = perf_counter()
gs.fit(Xtr_pca, y_train)
t1 = perf_counter()

print("Grid best CV roc_auc:", gs.best_score_)
print("Grid best params:", gs.best_params_)
print("Grid time (sec):", round(t1 - t0, 3))

save_cv_results(gs.cv_results_, f"grid_{model_key}.csv")

best_summary.append({
    "model": model_key,
    "search": "GridSearch",
    "best_cv_roc_auc": gs.best_score_,
    "best_params": gs.best_params_
})

best_g = build_model(model_key, gs.best_params_)
final_models_results.append(eval_model(f"{model_key} + PCA | Grid
best", best_g))

# ----- RANDOM SEARCH -----
print("\nRANDOM SEARCH SPACE:")
for k, v in random_spaces[model_key].items():
    if isinstance(v, list) and len(v) > 12:
        print(k, "->", f"list(len={len(v)}) sample:", v[:5], "...",
v[-3:])

```

```
        else:
            print(k, "->", v)

    rs = RandomizedSearchCV(
        estimator=models_base[model_key],
        param_distributions=random_spaces[model_key],
        n_iter=20,
        scoring="roc_auc",
        cv=cv,
        n_jobs=-1,
        refit=True,
        random_state=42
    )

    t0 = perf_counter()
    rs.fit(Xtr_pca, y_train)
    t1 = perf_counter()

    print("Random best CV roc_auc:", rs.best_score_)
    print("Random best params:", rs.best_params_)
    print("Random time (sec):", round(t1 - t0, 3))

    save_cv_results(rs.cv_results_, f"random_{model_key}.csv")

    best_summary.append({
        "model": model_key,
        "search": "RandomSearch",
        "best_cv_roc_auc": rs.best_score_,
        "best_params": rs.best_params_
    })

    best_r = build_model(model_key, rs.best_params_)
    final_models_results.append(eval_model(f"{model_key} + PCA | Random
best", best_r))

# ----- OPTUNA -----
print("\nOPTUNA SEARCH SPACE:")
if model_key in ["LogisticRegression", "LinearSVM"]:
    print("C: log float in [1e-3, 1e2]")
    print("class_weight: [None, 'balanced']")
    if model_key == "LogisticRegression":
        print("penalty: ['l1', 'l2']")
else:
    print("criterion: ['gini', 'entropy']")
```

```

print("max_depth: [None,3,5,8,12] categorical")
print("min_samples_split: int in [2,40]")
print("min_samples_leaf: int in [1,20]")
print("class_weight: [None, 'balanced']")

def objective(trial):
    if model_key == "LogisticRegression":
        params = {
            "C": trial.suggest_float("C", 1e-3, 1e2, log=True),
            "penalty": trial.suggest_categorical("penalty", ["l1",
"l2"]),
            "class_weight": trial.suggest_categorical("class_weight",
[None, "balanced"])
        }
        m = LogisticRegression(max_iter=3000, solver="liblinear",
random_state=42, **params)

    elif model_key == "LinearSVM":
        params = {
            "C": trial.suggest_float("C", 1e-3, 1e2, log=True),
            "class_weight": trial.suggest_categorical("class_weight",
[None, "balanced"])
        }
        m = LinearSVC(random_state=42, max_iter=5000, **params)

    else:
        params = {
            "criterion": trial.suggest_categorical("criterion",
["gini", "entropy"]),
            "max_depth": trial.suggest_categorical("max_depth", [None,
3, 5, 8, 12]),
            "min_samples_split": trial.suggest_int("min_samples_split",
2, 40),
            "min_samples_leaf": trial.suggest_int("min_samples_leaf",
1, 20),
            "class_weight": trial.suggest_categorical("class_weight",
[None, "balanced"])
        }
        m = DecisionTreeClassifier(random_state=42, **params)

    score = cross_val_score(m, Xtr_pca, y_train, scoring="roc_auc",
cv=cv, n_jobs=-1).mean()
    return score

sampler = TPESampler(seed=42)
study = optuna.create_study(direction="maximize", sampler=sampler)

```

```
t0 = perf_counter()
study.optimize(objective, n_trials=20, show_progress_bar=False)
t1 = perf_counter()

print("Optuna best CV roc_auc:", study.best_value)
print("Optuna best params:", study.best_trial.params)
print("Optuna time (sec):", round(t1 - t0, 3))

trials_df = study.trials_dataframe()
trials_df.to_csv(f"optuna_{model_key}.csv", index=False)
print("Saved:", f"optuna_{model_key}.csv", "| rows:", len(trials_df))

best_summary.append({
    "model": model_key,
    "search": "Optuna",
    "best_cv_roc_auc": study.best_value,
    "best_params": study.best_trial.params
})

best_o = build_model(model_key, study.best_trial.params)
final_models_results.append(eval_model(f"{model_key} + PCA | Optuna
best", best_o))

best_params_df = pd.DataFrame(best_summary)
final_compare_df =
pd.DataFrame(final_models_results).sort_values("roc_auc", ascending=False)

print("\n" + "="*80)
print("BEST PARAMS SUMMARY (CV)")
print("=="*80)
print(best_params_df.to_string(index=False))

print("\n" + "="*80)
print("FINAL TEST COMPARISON (sorted by roc_auc)")
print("=="*80)
print(final_compare_df.to_string(index=False))

best_params_df.to_csv("best_params_summary.csv", index=False)
final_compare_df.to_csv("final_test_comparison.csv", index=False)

print("\nSaved: best_params_summary.csv")
print("Saved: final_test_comparison.csv")

print("\nAlso saved per-model full results:")
```

```
print("grid_<Model>.csv , random_<Model>.csv , optuna_<Model>.csv")
```

در این قسمت کد وارد فاز تنظیم های پرپارامترها می شود. یعنی برای هر 3 مدل، سه روش تنظیم را اجرا می کنیم:

Grid Search: جستجوی کامل روی یک شبکه کوچک از مقادیر

Random Search: نمونه برداری تصادفی از یک فضای بزرگ تر

Optuna: بهینه سازی هوشمند (TPE) برای پیدا کردن ترکیب بهتر با تعداد آزمون محدود

و در نهایت بهترین تنظیمات هر روش را با Cross-Validation پیدا می کند. سپس بهترین مدل های به دست آمده را روی Test واقعی باتابع eval_model ارزیابی می کنیم. در آخر نتایج هم چاپ و هم به صورت CSV ذخیره می شوند.

```
def build_model(model_key, params):  
    ...  
    m.set_params(**params)  
    return m
```

این قسمت برای این است که بعد از Optuna, Grid, Random، بهترین پارامترها را برداریم و یک مدل واقعی بسازیم. اینجا فقط مدل ساخته می شود آموزش داخل eval_model انجام می شود.

Grid Search Space

شبکه کوچک و مشخصی است.

LR: C, penalty, class_weight

SVM: C, class_weight

DT: criterion, max_depth, min_samples_split, min_samples_leaf, class_weight

یعنی همه ترکیبها امتحان می شوند. Grid

Random Search Space

فضای بزرگ تر

مثلا C با logspace از 0.001 تا 100

عمق‌ها و `min_samples` های بیشتر برای DT

یعنی از این فضای فقط 20 تاً مونه تصادفی تست می‌شود.

حلقه اصلی روی سه مدل

```
for model_key in ["LogisticRegression", "LinearSVM", "DecisionTree"]:
```

برای هر مدل، سه مرحله انجام می‌شود:

GridSearchCV

```
gs = GridSearchCV(... scoring="roc_auc", cv=cv, n_jobs=-1, refit=True)  
gs.fit(Xtr_pca, y_train)
```

`scoring="roc_auc"` معیار انتخاب بهترین تنظیم است.

`n_jobs=-1` یعنی استفاده از همه هسته‌های CPU برای سرعت.

`refit=True` یعنی بعد از پیدا کردن بهترین پارامتر، همان بهترین مدل دوباره روی کل Train آموزش داده می‌شود و در `best_estimator_` آمده است.

زمان اجرا را با `perf_counter` اندازه گرفته‌ایم.

بهترین CV score و بهترین پارامتر چاپ می‌شود نتایج کامل Grid در `grid_<Model>.csv` ذخیره می‌گردد

سپس با `build_model + eval_model` روی Test واقعی ارزیابی می‌کنیم:

```
final_models_results.append(eval_model(f"{model_key} + PCA | Grid best",  
best_g))
```

RandomizedSearchCV

مشابه Grid است ولی فضای جستجو بزرگ‌تر است.

`n_iter=20` یعنی فقط 20 ترکیب بررسی می‌شود

خروجی‌ها هم مثل Grid ذخیره می‌شوند `random_<Model>.csv`

و ارزیابی نهایی روی Test انجام می‌گردد.

Optuna

اینجا یک تابع هدف تعریف می‌کنیم:

```
def objective(trial):
    ...
    score = cross_val_score(m, Xtr_pca, y_train, scoring="roc_auc", cv=cv,
    n_jobs=-1).mean()
    return score
```

در هر trial یک ترکیب پارامتر پیشنهاد می‌دهد. برای همان ترکیب، 5-fold ROC-AUC را با cross_val_score حساب می‌کنیم. سپس میانگین امتیاز را برمی‌گردانیم.

Optuna تلاش می‌کند در 20 آزمون به بهترین ترکیب برسد.

در نهایت بهترین مقدار (best_value) و پارامترها چاپ می‌شود.

لیست همه trial‌ها ذخیره می‌شود و بهترین مدل ساخته و روی Test ارزیابی می‌شود.

```
optuna_<Model>.csv
```

خروجی

```
=====
=====
TUNING MODEL: LogisticRegression
=====
=====
```

GRID SEARCH SPACE:

```
C -> [0.01, 0.1, 1, 10, 100]
penalty -> ['l1', 'l2']
class_weight -> [None, 'balanced']
Grid best CV roc_auc: 0.8423194344343938
Grid best params: {'C': 0.1, 'class_weight': None, 'penalty': 'l1'}
Grid time (sec): 3.005
Saved: grid_LogisticRegression.csv | rows: 20
```

RANDOM SEARCH SPACE:

```
C -> list(len=25) sample: [np.float64(0.001),
np.float64(0.0016155980984398745), np.float64(0.0026101572156825357),
np.float64(0.004216965034285823), np.float64(0.006812920690579615)] ...
```

```
[np.float64(38.31186849557293), np.float64(61.8965818891261),
np.float64(100.0)]
penalty -> ['l1', 'l2']
class_weight -> [None, 'balanced']
[I 2026-02-13 01:49:50, 815] A new study created in memory with name: no-name-1d6c2988-85c4-4a27-9a6a-e3140aa0aa96
Random best CV roc_auc: 0.8423121462178205
Random best params: {'penalty': 'l1', 'class_weight': None, 'C':
np.float64(0.19573417814876617)}
Random time (sec): 4.105
Saved: random_LogisticRegression.csv | rows: 20

OPTUNA SEARCH SPACE:
C: log float in [1e-3, 1e2]
class_weight: [None, 'balanced']
penalty: ['l1','l2']
[I 2026-02-13 01:49:51, 028] Trial 0 finished with value: 0.8422991893883566
and parameters: {'C': 0.0745934328572655, 'penalty': 'l1', 'class_weight':
None}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:51, 166] Trial 1 finished with value: 0.8416553969243725
and parameters: {'C': 0.0060252157362038605, 'penalty': 'l2', 'class_weight':
'balanced'}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:51, 282] Trial 2 finished with value: 0.7955080291852583
and parameters: {'C': 0.001267425589893723, 'penalty': 'l1', 'class_weight':
None}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:51, 441] Trial 3 finished with value: 0.8410593827690365
and parameters: {'C': 0.008260808399079604, 'penalty': 'l2', 'class_weight':
None}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:51, 749] Trial 4 finished with value: 0.8419056256933928
and parameters: {'C': 1.1462107403425035, 'penalty': 'l2', 'class_weight':
'balanced'}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:52, 032] Trial 5 finished with value: 0.8421477564439982
and parameters: {'C': 8.43101393208247, 'penalty': 'l2', 'class_weight':
None}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:52, 211] Trial 6 finished with value: 0.8419331589560034
and parameters: {'C': 1.0907475835157696, 'penalty': 'l1', 'class_weight':
'balanced'}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:52, 451] Trial 7 finished with value: 0.8421445172366322
and parameters: {'C': 11.015056790269638, 'penalty': 'l1', 'class_weight':
None}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:52, 565] Trial 8 finished with value: 0.8198150412594039
and parameters: {'C': 0.00407559644007287, 'penalty': 'l1', 'class_weight':
None}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:52, 783] Trial 9 finished with value: 0.8421437074347906
and parameters: {'C': 2.0540519425388455, 'penalty': 'l2', 'class_weight':
None}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:52, 961] Trial 10 finished with value: 0.8421931053471216
and parameters: {'C': 0.07453892933860191, 'penalty': 'l1', 'class_weight':
'balanced'}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:53, 256] Trial 11 finished with value: 0.8421752897066088
and parameters: {'C': 0.05423185466354641, 'penalty': 'l1', 'class_weight':
'balanced'}. Best is trial 0 with value: 0.8422991893883566.
[I 2026-02-13 01:49:53, 497] Trial 12 finished with value: 0.8421680014900353
and parameters: {'C': 0.11547408571799433, 'penalty': 'l1', 'class_weight':
'balanced'}. Best is trial 0 with value: 0.8422991893883566.
```

```
[I 2026-02-13 01:49:53,696] Trial 13 finished with value: 0.8421939151489631  
and parameters: {'C': 0.07534500668676802, 'penalty': 'l1', 'class_weight':  
'balanced'}. Best is trial 0 with value: 0.8422991893883566.  
[I 2026-02-13 01:49:53,854] Trial 14 finished with value: 0.8406561014519747  
and parameters: {'C': 0.026870239798129827, 'penalty': 'l1', 'class_weight':  
None}. Best is trial 0 with value: 0.8422991893883566.  
[I 2026-02-13 01:49:54,050] Trial 15 finished with value: 0.8420829722966789  
and parameters: {'C': 0.22401322201281426, 'penalty': 'l1', 'class_weight':  
'balanced'}. Best is trial 0 with value: 0.8422991893883566.  
[I 2026-02-13 01:49:54,236] Trial 16 finished with value: 0.8422425032594525  
and parameters: {'C': 0.4604234767893719, 'penalty': 'l1', 'class_weight':  
None}. Best is trial 0 with value: 0.8422991893883566.  
[I 2026-02-13 01:49:54,486] Trial 17 finished with value: 0.8421461368403153  
and parameters: {'C': 75.61683084280057, 'penalty': 'l1', 'class_weight':  
None}. Best is trial 0 with value: 0.8422991893883566.  
[I 2026-02-13 01:49:54,665] Trial 18 finished with value: 0.8422222582134152  
and parameters: {'C': 0.49899998666091444, 'penalty': 'l1', 'class_weight':  
None}. Best is trial 0 with value: 0.8422991893883566.  
[I 2026-02-13 01:49:54,841] Trial 19 finished with value: 0.8421550446605715  
and parameters: {'C': 3.8202903332380145, 'penalty': 'l1', 'class_weight':  
None}. Best is trial 0 with value: 0.8422991893883566.  
Optuna best CV roc_auc: 0.8422991893883566  
Optuna best params: {'C': 0.0745934328572655, 'penalty': 'l1',  
'class_weight': None}  
Optuna time (sec): 4.029  
Saved: optuna_LogisticRegression.csv | rows: 20
```

```
=====  
===  
TUNING MODEL: LinearSVM  
=====  
===  
=====
```

```
GRID SEARCH SPACE:  
C -> [0.01, 0.1, 1, 10, 100]  
class_weight -> [None, 'balanced']  
Grid best CV roc_auc: 0.8416132872286152  
Grid best params: {'C': 100, 'class_weight': 'balanced'}  
Grid time (sec): 1.326  
Saved: grid_LinearSVM.csv | rows: 10
```

```
RANDOM SEARCH SPACE:  
C -> list(len=25) sample: [np.float64(0.001),  
np.float64(0.0016155980984398745), np.float64(0.0026101572156825357),  
np.float64(0.004216965034285823), np.float64(0.006812920690579615)] ...  
[np.float64(38.31186849557293), np.float64(61.8965818891261),  
np.float64(100.0)]  
class_weight -> [None, 'balanced']  
[I 2026-02-13 01:49:59,194] A new study created in memory with name: no-name-  
8773d417-ee29-4986-8936-057469310802  
Random best CV roc_auc: 0.8416132872286152  
Random best params: {'class_weight': 'balanced', 'C':  
np.float64(5.623413251903491)}  
Random time (sec): 2.744  
Saved: random_LinearSVM.csv | rows: 20
```

```
OPTUNA SEARCH SPACE:
```

```
C: log float in [1e-3, 1e2]
class_weight: [None, 'balanced']
[I 2026-02-13 01:49:59,390] Trial 0 finished with value: 0.8402252868723024
and parameters: {'C': 0.0745934328572655, 'class_weight': None}. Best is
trial 0 with value: 0.8402252868723024.
[I 2026-02-13 01:49:59,569] Trial 1 finished with value: 0.8402463417201812
and parameters: {'C': 0.9846738873614566, 'class_weight': None}. Best is
trial 1 with value: 0.8402463417201812.
[I 2026-02-13 01:49:59,827] Trial 2 finished with value: 0.8393199284135171
and parameters: {'C': 0.0019517224641449498, 'class_weight': None}. Best is
trial 1 with value: 0.8402463417201812.
[I 2026-02-13 01:50:00,057] Trial 3 finished with value: 0.8416140970304566
and parameters: {'C': 3.4702669886504163, 'class_weight': 'balanced'}. Best
is trial 3 with value: 0.8416140970304566.
[I 2026-02-13 01:50:00,243] Trial 4 finished with value: 0.8402503907293886
and parameters: {'C': 14.528246637516036, 'class_weight': None}. Best is
trial 3 with value: 0.8416140970304566.
[I 2026-02-13 01:50:00,540] Trial 5 finished with value: 0.8416092382194078
and parameters: {'C': 0.008260808399079604, 'class_weight': 'balanced'}. Best
is trial 3 with value: 0.8416140970304566.
[I 2026-02-13 01:50:00,785] Trial 6 finished with value: 0.8416132872286152
and parameters: {'C': 0.14445251022763064, 'class_weight': 'balanced'}. Best
is trial 3 with value: 0.8416140970304566.
[I 2026-02-13 01:50:01,129] Trial 7 finished with value: 0.8416173362378228
and parameters: {'C': 0.004982752357076452, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:01,458] Trial 8 finished with value: 0.840249580927547
and parameters: {'C': 0.19069966103000435, 'class_weight': None}. Best is
trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:01,987] Trial 9 finished with value: 0.8402455319183396
and parameters: {'C': 0.3725393839578866, 'class_weight': None}. Best is
trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:02,262] Trial 10 finished with value: 0.8416027598046758
and parameters: {'C': 0.010916771197512777, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:02,433] Trial 11 finished with value: 0.8416124774267736
and parameters: {'C': 18.428603639984882, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:02,696] Trial 12 finished with value: 0.8416140970304566
and parameters: {'C': 3.671423529735164, 'class_weight': 'balanced'}. Best is
trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:02,931] Trial 13 finished with value: 0.8416124774267738
and parameters: {'C': 60.01447217163458, 'class_weight': 'balanced'}. Best is
trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:03,241] Trial 14 finished with value: 0.8416124774267736
and parameters: {'C': 1.3627563818737505, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:03,394] Trial 15 finished with value: 0.8416084284175662
and parameters: {'C': 0.02533989267880571, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:03,606] Trial 16 finished with value: 0.8415193502150025
and parameters: {'C': 0.0023181233009956915, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:03,769] Trial 17 finished with value: 0.8416132872286152
and parameters: {'C': 4.1334779054662825, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
```

```

[I 2026-02-13 01:50:03,991] Trial 18 finished with value: 0.8415970911917855
and parameters: {'C': 0.03575861199035915, 'class_weight': 'balanced'}. Best
is trial 7 with value: 0.8416173362378228.
[I 2026-02-13 01:50:04,141] Trial 19 finished with value: 0.8416108578230906
and parameters: {'C': 0.778750172539758, 'class_weight': 'balanced'}. Best is
trial 7 with value: 0.8416173362378228.
Optuna best CV roc_auc: 0.8416173362378228
Optuna best params: {'C': 0.004982752357076452, 'class_weight': 'balanced'}
Optuna time (sec): 4.945
Saved: optuna_LinearSVM.csv | rows: 20

=====
===
TUNING MODEL: DecisionTree
=====
===

GRID SEARCH SPACE:
criterion -> ['gini', 'entropy']
max_depth -> [None, 5, 10]
min_samples_split -> [2, 10]
min_samples_leaf -> [1, 5]
class_weight -> [None, 'balanced']
Grid best CV roc_auc: 0.8029379610809235
Grid best params: {'class_weight': 'balanced', 'criterion': 'gini',
'max_depth': 5, 'min_samples_leaf': 5, 'min_samples_split': 2}
Grid time (sec): 34.341
Saved: grid_DecisionTree.csv | rows: 48

RANDOM SEARCH SPACE:
criterion -> ['gini', 'entropy']
max_depth -> [None, 3, 5, 8, 12]
min_samples_split -> [2, 5, 10, 20, 40]
min_samples_leaf -> [1, 2, 5, 10, 20]
class_weight -> [None, 'balanced']
[I 2026-02-13 01:50:50,029] A new study created in memory with name: no-name-
d3dba24b-ea79-404c-849f-284ca63d8293
Random best CV roc_auc: 0.8036935061990331
Random best params: {'min_samples_split': 5, 'min_samples_leaf': 10,
'max_depth': 5, 'criterion': 'gini', 'class_weight': 'balanced'}
Random time (sec): 11.223
Saved: random_DecisionTree.csv | rows: 20

OPTUNA SEARCH SPACE:
criterion: ['gini','entropy']
max_depth: [None,3,5,8,12]  categorical
min_samples_split: int in [2,40]
min_samples_leaf: int in [1,20]
class_weight: [None, 'balanced']
[I 2026-02-13 01:50:50,784] Trial 0 finished with value: 0.7601237377213795
and parameters: {'criterion': 'entropy', 'max_depth': None,
'min_samples_split': 35, 'min_samples_leaf': 13, 'class_weight': None}. Best
is trial 0 with value: 0.7601237377213795.
[I 2026-02-13 01:50:51,430] Trial 1 finished with value: 0.7146043713103405
and parameters: {'criterion': 'gini', 'max_depth': 12, 'min_samples_split':
18, 'min_samples_leaf': 6, 'class_weight': None}. Best is trial 0 with value:
0.7601237377213795.

```

```
[I 2026-02-13 01:50:51,731] Trial 2 finished with value: 0.7867467830621847
and parameters: {'criterion': 'entropy', 'max_depth': 3, 'min_samples_split': 3, 'min_samples_leaf': 13, 'class_weight': None}. Best is trial 2 with value: 0.7867467830621847.
[I 2026-02-13 01:50:52,487] Trial 3 finished with value: 0.7527419890352831
and parameters: {'criterion': 'entropy', 'max_depth': None, 'min_samples_split': 6, 'min_samples_leaf': 10, 'class_weight': 'balanced'}. Best is trial 2 with value: 0.7867467830621847.
[I 2026-02-13 01:50:53,123] Trial 4 finished with value: 0.7740806724594493
and parameters: {'criterion': 'entropy', 'max_depth': 12, 'min_samples_split': 32, 'min_samples_leaf': 19, 'class_weight': None}. Best is trial 2 with value: 0.7867467830621847.
[I 2026-02-13 01:50:53,653] Trial 5 finished with value: 0.7781697668580498
and parameters: {'criterion': 'gini', 'max_depth': 8, 'min_samples_split': 34, 'min_samples_leaf': 8, 'class_weight': 'balanced'}. Best is trial 2 with value: 0.7867467830621847.
[I 2026-02-13 01:50:54,111] Trial 6 finished with value: 0.7911302404301667
and parameters: {'criterion': 'entropy', 'max_depth': 3, 'min_samples_split': 33, 'min_samples_leaf': 15, 'class_weight': 'balanced'}. Best is trial 6 with value: 0.7911302404301667.
[I 2026-02-13 01:50:54,534] Trial 7 finished with value: 0.7867467830621847
and parameters: {'criterion': 'entropy', 'max_depth': 3, 'min_samples_split': 14, 'min_samples_leaf': 7, 'class_weight': None}. Best is trial 6 with value: 0.7911302404301667.
[I 2026-02-13 01:50:55,459] Trial 8 finished with value: 0.7515119000380607
and parameters: {'criterion': 'gini', 'max_depth': 12, 'min_samples_split': 21, 'min_samples_leaf': 11, 'class_weight': None}. Best is trial 6 with value: 0.7911302404301667.
[I 2026-02-13 01:50:56,231] Trial 9 finished with value: 0.782648375942407
and parameters: {'criterion': 'gini', 'max_depth': 8, 'min_samples_split': 18, 'min_samples_leaf': 16, 'class_weight': None}. Best is trial 6 with value: 0.7911302404301667.
[I 2026-02-13 01:50:56,899] Trial 10 finished with value: 0.7945099484156227
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 29, 'min_samples_leaf': 1, 'class_weight': 'balanced'}. Best is trial 10 with value: 0.7945099484156227.
[I 2026-02-13 01:50:57,407] Trial 11 finished with value: 0.7938483403111259
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 27, 'min_samples_leaf': 2, 'class_weight': 'balanced'}. Best is trial 10 with value: 0.7945099484156227.
[I 2026-02-13 01:50:57,887] Trial 12 finished with value: 0.7938483403111259
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 27, 'min_samples_leaf': 1, 'class_weight': 'balanced'}. Best is trial 10 with value: 0.7945099484156227.
[I 2026-02-13 01:50:58,374] Trial 13 finished with value: 0.7972187355754047
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 40, 'min_samples_leaf': 1, 'class_weight': 'balanced'}. Best is trial 13 with value: 0.7972187355754047.
[I 2026-02-13 01:50:58,851] Trial 14 finished with value: 0.7976260659016738
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 40, 'min_samples_leaf': 5, 'class_weight': 'balanced'}. Best is trial 14 with value: 0.7976260659016738.
[I 2026-02-13 01:50:59,344] Trial 15 finished with value: 0.7975629013580376
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 40, 'min_samples_leaf': 4, 'class_weight': 'balanced'}. Best is trial 14 with value: 0.7976260659016738.
```

```
[I 2026-02-13 01:50:59,823] Trial 16 finished with value: 0.7976260659016738
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 39, 'min_samples_leaf': 5, 'class_weight': 'balanced'}. Best is trial 14 with
value: 0.7976260659016738.
[I 2026-02-13 01:51:00,315] Trial 17 finished with value: 0.7975629013580376
and parameters: {'criterion': 'entropy', 'max_depth': 5, 'min_samples_split': 38, 'min_samples_leaf': 4, 'class_weight': 'balanced'}. Best is trial 14 with
value: 0.7976260659016738.
[I 2026-02-13 01:51:00,745] Trial 18 finished with value: 0.8046928016714311
and parameters: {'criterion': 'gini', 'max_depth': 5, 'min_samples_split': 29, 'min_samples_leaf': 4, 'class_weight': 'balanced'}. Best is trial 18 with
value: 0.8046928016714311.
[I 2026-02-13 01:51:01,132] Trial 19 finished with value: 0.8048341120927709
and parameters: {'criterion': 'gini', 'max_depth': 5, 'min_samples_split': 24, 'min_samples_leaf': 8, 'class_weight': 'balanced'}. Best is trial 19 with
value: 0.8048341120927709.
Optuna best CV roc_auc: 0.8048341120927709
Optuna best params: {'criterion': 'gini', 'max_depth': 5,
'min_samples_split': 24, 'min_samples_leaf': 8, 'class_weight': 'balanced'}
Optuna time (sec): 11.102
Saved: optuna_DecisionTree.csv | rows: 20
```

```
=====
===
BEST PARAMS SUMMARY (CV)
=====

=====
model      search    best_cv_roc_auc
best_params
LogisticRegression GridSearch      0.842319
{'C': 0.1, 'class_weight': None, 'penalty': 'l1'}
LogisticRegression RandomSearch     0.842312
{'penalty': 'l1', 'class_weight': None, 'C': 0.19573417814876617}
LogisticRegression Optuna         0.842299
{'C': 0.0745934328572655, 'penalty': 'l1', 'class_weight': None}
    LinearSVM GridSearch      0.841613
{'C': 100, 'class_weight': 'balanced'}
    LinearSVM RandomSearch     0.841613
{'class_weight': 'balanced', 'C': 5.623413251903491}
    LinearSVM Optuna         0.841617
{'C': 0.004982752357076452, 'class_weight': 'balanced'}
    DecisionTree GridSearch     0.802938 {'class_weight':
'balanced', 'criterion': 'gini', 'max_depth': 5, 'min_samples_leaf': 5,
'min_samples_split': 2}
    DecisionTree RandomSearch     0.803694 {'min_samples_split': 5,
'min_samples_leaf': 10, 'max_depth': 5, 'criterion': 'gini', 'class_weight':
'balanced'}
    DecisionTree Optuna         0.804834 {'criterion': 'gini',
'max_depth': 5, 'min_samples_split': 24, 'min_samples_leaf': 8,
'class_weight': 'balanced'}
```

=====

=====

FINAL TEST COMPARISON (sorted by roc_auc)

=====

=====

		model	n_features_after	fit_time_sec
inference_time_sec	accuracy	f1	roc_auc	
0.034183	0.800995	0.603399	0.828904	20 0.169916
0.008643	0.800995	0.604520	0.828876	20 0.140862
0.013310	0.800284	0.600284	0.828739	20 0.174155
0.016498	0.719972	0.600406	0.828014	20 0.156667
0.008880	0.719972	0.600406	0.828011	20 0.156015
0.014392	0.719261	0.599797	0.827882	20 0.136680
0.004410	0.701493	0.593810	0.788519	DecisionTree + PCA Grid best 20 0.227061
0.005058	0.702203	0.594385	0.788401	DecisionTree + PCA Random best 20 0.230056
0.004549	0.701493	0.593810	0.787594	DecisionTree + PCA Optuna best 20 0.231193

A) Logistic Regression

Grid best CV roc_auc: **0.842319**

best params: C=0.1, penalty=l1, class_weight=None
time: **6.848s**

Random best CV roc_auc: **0.842312**

best params: C≈0.1957, l1, None
time: **3.897s**

Optuna best CV roc_auc: **0.842299**

best params: C≈0.0745, l1, None
time: **4.029s**

هر سه روش تقریبا به یک نتیجه رسیدند یعنی سطح عملکرد LogisticRegression نسبت به این پارامترها یک ناحیه تخت دارد.

. در هر سه روش بهترین بوده یعنی sparse شدن وزن‌ها کمک کرده.

balanced class_weight=None بهترین بوده چرا که با وجود عدم توازن کلاس‌ها، اینجا وزن‌دهی ROC-AUC کمک نکرده گاهی F1 به balanced ROC-AUC لزوما نه.

از نظر هزینه محاسباتی Grid کنتر از Random,Optuna است چون همه ترکیب‌ها را می‌رود.
Random,Optuna سریع‌تر و تقریبا همان کیفیت را می‌دهند.

B) Linear SVM

Grid best CV roc_auc: **0.841613**

params: C=100, class_weight=balanced

time: **1.374s**

Random best CV roc_auc: **0.841613**

params: C≈5.623, balanced

time: **2.496s**

Optuna best CV roc_auc: **0.841617**

params: C≈0.00498, balanced

time: **4.945s**

باز هم CV ROC-AUC تقریبا ثابت است(0.841613)

اینکه Optuna یک C خیلی کوچک داده است ولی تقریبا همان ROC-AUC را گرفته به این معناست که یا داده در فضای PCA خیلی راحت جدا می شود یا ROC-AUC نسبت به مقیاس C حساسیت خیلی زیادی ندارد.

اینجا از همه سریع تر شده چون فضای Grid کوچک بوده (فقط ۱۰ حالت).

C) Decision Tree

Grid best CV roc_auc: **0.802938**

params: depth=5, min_leaf=5, ...

time: **32.102s**

Random best CV roc_auc: **0.803694**

time: **11.025s**

Optuna best CV roc_auc: **0.804834**

time: **11.102s**

درخت تصمیم خیلی پایین تر از دو مدل خطی است حدود 0.80 در CV

در Grid تعداد ترکیبها ۴۸ تاست و هر کدام ۵-فولد یعنی حدود ۲۴۰ بار fit به همین دلیل کند است.

بهترین شده چون جستجو را هوشمندتر پیش می برد و لازم نیست همه حالتها را brute Optuna force بروند.

پارامترهای بهترین‌ها هم منطقی‌اند $\text{min_samples_leaf}=5$ و $\text{depth}=5$ بزرگ‌تر یعنی جلوگیری از overfitting

(Final Test Comparison sorted by roc_auc)

بهترین‌ها از نظر roc_auc روی Test

LogisticRegression + PCA | Grid best

$\text{roc_auc} \approx 0.828904$

$\text{accuracy} \approx 0.800995$

$f1 \approx 0.603399$

$\text{fit_time} \approx 0.130s$

LogisticRegression + PCA | Optuna best

$\text{roc_auc} \approx 0.828739$

$f1 \approx 0.600284$ (کمی بهتر)

$\text{inference_time} \approx 0.013310$ در Grid خیلی کمتر از

LogisticRegression + PCA | Random best

$\text{roc_auc} \approx 0.828876$

بعد از آن‌ها LinearSVM با $\text{roc_auc} \approx 0.8280$ accuracy می‌آید خیلی نزدیک، ولی حدود 0.72 دارد

و درخت تصمیم خیلی عقب‌تر

$\text{roc_auc} \approx 0.788-0.789$

اینکه CV برای لاجستیک حدود 0.842 بوده ولی روی Test حدود 0.829 شده طبیعی است چرا که CV روی Train انجام شده و Test یک مجموعه جداست. اختلاف 0.02–0.01 کاملاً معمول است. از طرفی اینکه هر سه نسخه (Grid/Random/Optuna) روی Test تقریباً برابرند یعنی تیونینگ اینجا بیشتر ریز تنظیم بوده و مدل پایه هم تقریباً همین عملکرد را داشته.

کدام مدل و کدام روش تیونینگ بهتر است؟

اگر معیار اصلی دقت باشد:

LogisticRegression + PCA بهترین و پایدارترین گزینه است هم $f1$ ، هم accuracy، هم roc_auc در Test از بقیه بهتر یا برابر است.

اگر معیار اصلی سادگی باشد:

برای LogisticRegression خیلی قابل دفاع است چون فضای جستجو کوچک و مشخص است (۲۰ حالت) و بهترین پارامترها واضح‌اند.

اگر معیار اصلی هزینه محاسباتی تیونینگ باشد:

برای LogisticRegression ، RandomSearch یا Optuna تقریبا همان کیفیت را با زمان کمتر می‌دهند.

برای DecisionTree ، Optuna بeter از Grid است چون Grid خیلی سنگین می‌شود.

فصل 9 - بخش ششم

۶. ارزیابی و تکرارپذیری (Evaluation & Reproducibility)

- تنظیم دقیق Random State (یا Seed) در تمام بخش‌های کد (تقسیم داده، وزن‌دهی اولیه مدل‌ها و ...) برای تضمین تکرارپذیری کامل نتایج.
- توضیح شفاف نحوه تقسیم داده‌ها (Train/Validation/Test Split) و منطق پشت آن (مثلً Stratified K-Fold).

هدف تکرارپذیری

در پروژه‌های یادگیری ماشین، بخش‌هایی مثل تقسیم داده، ساخت برخی مدل‌ها و بعضی الگوریتم‌های کاهش بعد می‌توانند رفتار تصادفی داشته باشند. اگر این تصادفی بودن کنترل نشود، با هر بار اجرا ممکن است نتایج کمی تغییر کند و مقایسه روش‌ها و مدل‌ها قابل اعتماد نباشد. بنابراین در این پروژه، مقدار ثابت 42 به عنوان random_state در تمام بخش‌های حساس تنظیم شد تا اجرای مجدد کد، خروجی یکسان تولید کند و نتایج قابل بازتولید باشند.

بخش‌هایی در کد ما که تکرارپذیری در آن‌ها کنترل شد:

در کل کد، مقدار random_state برابر 42 در نقاط زیر اعمال شده است

- تقسیم داده‌ها

در مقدار train_test_split مقدار random_state=42 تنظیم شد.

همچنین stratify=y فعال شد تا نسبت کلاس‌ها در هر دو بخش آموزش و آزمون ثابت و مشابه کل داده باقی بماند. این کار به ویژه برای مسئله Churn که عموماً نامتوازن است ضروری است.

- اعتبارسنجی در مرحله تنظیم ابرپارامترها

برای تیونینگ از StratifiedKFold استفاده شد.

با random_state=42 و shuffle=True ترتیب نمونه‌ها قبل از ساخت فولد‌ها ثابت شد. چون StratifiedKFold است، توزیع کلاس‌ها در همه فولد‌ها مشابه می‌ماند و مقایسه تنظیمات مختلف منصفانه‌تر می‌شود.

- مدل‌ها

برای LogisticRegression مقدار random_state=42 تنظیم شد تا هرگونه تصادفی بودن داخلی کنترل شود.

برای DecisionTreeClassifier مقدار random_state=42 را تنظیم کردیم چون درخت تصمیم می‌تواند در برخی حالت‌ها رفتار تصادفی داشته باشد.

برای LinearSVC نیز random_state=42 گذاشته شد تا اگر در روند بهینه‌سازی یا شافل داخلی تصادفی بودن وجود داشت، کنترل شود.

- کاهش بعد

برای PCA مقدار random_state=42 را قرار دادیم.
اگر در جایی از t-SNE استفاده شود، random_state=42 نیز باید تنظیم شود چون t-SNE به مقداردهی اولیه و روند تصادفی حساس است.

- جلوگیری از نشت داده

تمام مراحل پیش‌پردازش مانند One-Hot Encoding، استانداردسازی و PCA فقط روی داده آموزش فیت شدند و سپس همان تبدیل‌ها روی داده آزمون اعمال شد.
این کار باعث می‌شود اطلاعات آزمون وارد آموزش نشود و ارزیابی روی داده دیده‌نشده واقعی تر باشد.

ما داده را تقسیم می‌کنیم تا بتوانیم تعیین‌پذیری مدل را بسنجیم. یعنی مدل را روی بخشی از داده آموزش می‌دهیم و روی بخشی دیگر که در آموزش دیده نشده، ارزیابی می‌کنیم. این کار جلوی این را می‌گیرد که مدل فقط داده را حفظ کند و روی داده جدید ضعیف باشد.

بخش اول Test Split و Train

برای یادگیری مدل و انجام تنظیمات و انتخاب مدل استفاده می‌شود.
باشد کاملاً کنار گذاشته شود و فقط در انتهای برای گزارش نهایی استفاده شود.

نسبت 20/80 یک انتخاب رایج است زیرا داده کافی برای آموزش باقی می‌ماند و در عین حال یک مجموعه تست مستقل برای ارزیابی واقعی داریم

اگر در حین انتخاب هایپرپارامتر یا تصمیم‌گیری‌های مدل‌سازی از Test استفاده کنیم، مدل به صورت غیرمستقیم روی Test تنظیم می‌شود و نتیجه تست دیگر واقعی نیست. این مشکل را Data Leakage یا نشت اطلاعات می‌گویند.

بخش دوم stratify

در مسئله Churn معمولاً تعداد کلاس‌ها برابر نیست. معمولاً تعداد No بیشتر از Yes است. اگر تقسیم داده را کاملاً تصادفی انجام دهیم ممکن است. در Train تعداد Yes خیلی کمتر یا بیشتر از حالت واقعی شود یا در Test تعداد Yes خیلی کم شود این باعث می‌شود ارزیابی غلط شود. مثلاً اگر در Test تعداد Yes کم شود، مدل ممکن است ظاهرا Accuracy خوبی بگیرد چون بیشتر No پیش‌بینی می‌کند، ولی در واقع برای تشخیص churn ضعیف است.

وقتی می‌گوییم stratify=y یعنی در Train و Test نسبت کلاس‌ها تقریباً مثل نسبت کلاس‌ها در کل دیتاست باقی می‌ماند یعنی درصد Yes و No در هر دو بخش نزدیک به هم و نزدیک به کل داده می‌ماند. درنتیجه استفاده از stratify ارزیابی منصفانه‌تر و پایدارتر می‌شود مقایسه مدل‌ها قابل اعتمادتر می‌شود و معیارهایی مثل F1 و ROC-AUC و Kمتر دچار نوسان می‌شوند مخصوصاً در داده‌های نامتوازن، stratify تقریباً ضروری است

بخش سوم Train Validation Test Split

ما یک Validation ثابت جداگانه نساختیم. به جای آن این کار مراحل زیر را انجام دادیم یک بار داده را به Train و Test تقسیم کردیم و برای ساخت Validation از داخل Train از روش Cross-Validation استفاده کردیم. یعنی Validation ثابت و دست نخورده می‌ماند Test به صورت چرخشی داخل Train ساخته می‌شود. این روش بهتر از ساخت یک validation ثابت است، چون از داده‌ی Train بهتر استفاده می‌کند و برآورد عملکرد پایدارتر است.

بخش چهارم Stratified K-Fold

در Fold-K ، داده Train به K قسمت تقسیم می شود. اگر K برابر 5 باشد:
در هر تکرار 4 قسمت برای آموزش

1 قسمت برای اعتبارسنجی

این کار 5 بار تکرار می شود تا هر قسمت یک بار نقش validation را داشته باشد
در نهایت عملکرد مدل روی validation برابر است با میانگین عملکرد در همه فولدها.

از Stratified K-Fold استفاده کردیم. چرا که همان منطق stratify اینجا هم مهم است. اگر فولدها stratified نباشند ممکن است یک فولد تعداد churn خیلی کم داشته باشد، یک فولد تعداد churn خیلی زیاد داشته باشد این باعث نوسان شدید و انتخاب اشتباہ های پرپارامتر می شود.

پس Stratified K-Fold تضمین می کند در هر فولد هم نسبت کلاس ها حفظ شود.

shuffle=True

اگر داده ها به هر دلیلی مرتب شده باشند، مثلًا رکوردهای مشابه کنار هم آمده باشند، تقسیم بدون shuffle می تواند فولد های غیر نماینده بسازد. داده را قبل از فولد بندی مخلوط می کند تا فولد ها نماینده تر شوند.

n_splits=5

5 تعادل خوبی بین دقت برآورد و هزینه محاسباتی است فولد های کمتر مثل 3 ممکن است ناپایدار تر باشند
فولد های بیشتر مثل 10 هزینه را زیاد می کند

بخش پنجم CV در تقسیم داده و random_state

تقسیم داده و shuffle ذاتاً تصادفی هستند. اگر random_state ثابت نگذاریم هر بار اجرای کد، Train و Test متفاوت می شوند و نتیجه مدل و تیونینگ متفاوت می شود

وقتی random_state=42 می گذاریم، تقسیم ها دقیقاً تکرار پذیر می شوند و نتایج بین اجرایها ثابت می مانند در نهایت مقایسه بین مدل ها و روش ها منصفانه تر می شود. که ما این کار را هم در StratifiedKFold رعایت کردیم، پس نتایج قابل باز تولید هستند.

فصل 10 - بخش هفتم

۷. تحلیل نتایج و مصورسازی (Visualization & Analysis)

- مقایسه نتایج حداقل دو روش انتخاب شده با معیارهای مختلف (مانند F1-Score، Recall، Precision) (مانند Loss، Learning Curves، Confusion Matrix).
- رسم تمامی نمودارهای ممکن و مرتبط (مانند ROC Curve، Curves).
- تحلیل و تفسیر عمیق نتایج (چرا یک مدل بهتر عمل کرد؟ چرا مدل دچار Overfitting شد یا نشد؟).

در این قسمت دیگر تمام موارد نیاز داریم و فقط نیاز داریم مقایسه ای بین هر سه مدل انجام دهیم و نمودارهای لازم را برای انجام این مقایسه رسم کنیم.

```
#7
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.metrics import (
    accuracy_score, precision_score, recall_score, f1_score,
    roc_auc_score,
    confusion_matrix, ConfusionMatrixDisplay,
    roc_curve, precision_recall_curve, average_precision_score
)

from sklearn.model_selection import StratifiedKFold, learning_curve,
validation_curve

best_params = {
    "LogisticRegression": {"C": 0.0745934328572655, "penalty": "l1",
    "class_weight": None},
    "LinearSVM": {"C": 0.004982752357076452, "class_weight": "balanced"},
    "DecisionTree": {"criterion": "gini", "max_depth": 5,
    "min_samples_split": 24, "min_samples_leaf": 8, "class_weight": "balanced"}
}

Xte_scaled = scaler.transform(X_test_ohe)
Xte_pca = pca.transform(Xte_scaled)
```

```

def get_pred_and_score(model, X):
    if hasattr(model, "predict_proba"):
        score = model.predict_proba(X)[:, 1]
        pred = (score >= 0.5).astype(int)
    else:
        score = model.decision_function(X)
        pred = (score >= 0).astype(int)
    return pred, score

final_models = {}
final_metrics = []

for key in ["LogisticRegression", "LinearSVM", "DecisionTree"]:
    model = build_model(key, best_params[key])
    model.fit(Xtr_pca, y_train)
    final_models[key] = model

    pred, score = get_pred_and_score(model, Xte_pca)

    final_metrics.append({
        "model": key,
        "accuracy": accuracy_score(y_test, pred),
        "precision": precision_score(y_test, pred, zero_division=0),
        "recall": recall_score(y_test, pred, zero_division=0),
        "f1": f1_score(y_test, pred, zero_division=0),
        "roc_auc": roc_auc_score(y_test, score),
        "avg_precision": average_precision_score(y_test, score)
    })

metrics_df = pd.DataFrame(final_metrics).sort_values("roc_auc",
ascending=False)
print("\n===== FINAL METRICS (TEST) =====")
print(metrics_df.to_string(index=False))

metrics_df.to_csv("final_metrics_after_tuning.csv", index=False)
print("\nSaved: final_metrics_after_tuning.csv")

# =====
# Confusion Matrix
# =====
for key, model in final_models.items():
    pred, score = get_pred_and_score(model, Xte_pca)
    cm = confusion_matrix(y_test, pred)

```

```
disp = ConfusionMatrixDisplay(confusion_matrix=cm)

plt.figure()
disp.plot(values_format="d")
plt.title(f"Confusion Matrix - {key} (Tuned) ")
plt.show()

# =====
# ROC Curves
# =====
plt.figure()
for key, model in final_models.items():
    pred, score = get_pred_and_score(model, Xte_pca)
    fpr, tpr, _ = roc_curve(y_test, score)
    auc = roc_auc_score(y_test, score)
    plt.plot(fpr, tpr, label=f"{key} (AUC={auc:.3f})")

plt.plot([0, 1], [0, 1], linestyle="--", label="Random")
plt.xlabel("False Positive Rate")
plt.ylabel("True Positive Rate")
plt.title("ROC Curves - Tuned Models")
plt.legend()
plt.show()

# =====
# Precision-Recall Curves
# =====
plt.figure()
for key, model in final_models.items():
    pred, score = get_pred_and_score(model, Xte_pca)
    prec, rec, _ = precision_recall_curve(y_test, score)
    ap = average_precision_score(y_test, score)
    plt.plot(rec, prec, label=f"{key} (AP={ap:.3f})")

plt.xlabel("Recall")
plt.ylabel("Precision")
plt.title("Precision-Recall Curves - Tuned Models")
plt.legend()
plt.show()

# =====
# Learning Curves (train size vs score)
```

```

# =====
cv_lc = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

def plot_learning_curve(estimator, title):
    train_sizes, train_scores, val_scores = learning_curve(
        estimator,
        Xtr_pca, y_train,
        cv=cv_lc,
        scoring="roc_auc",
        train_sizes=np.linspace(0.1, 1.0, 5),
        n_jobs=-1
    )

    train_mean = train_scores.mean(axis=1)
    train_std = train_scores.std(axis=1)
    val_mean = val_scores.mean(axis=1)
    val_std = val_scores.std(axis=1)

    plt.figure()
    plt.plot(train_sizes, train_mean, label="Train ROC-AUC")
    plt.plot(train_sizes, val_mean, label="CV ROC-AUC")
    plt.fill_between(train_sizes, train_mean-train_std,
    train_mean+train_std, alpha=0.2)
    plt.fill_between(train_sizes, val_mean-val_std, val_mean+val_std,
    alpha=0.2)
    plt.xlabel("Training set size")
    plt.ylabel("ROC-AUC")
    plt.title(title)
    plt.legend()
    plt.show()

for key, model in final_models.items():
    plot_learning_curve(model, f"Learning Curve - {key} (Tuned)")

# =====
# Validation Curve
# =====

def plot_validation_curve(estimator, param_name, param_range, title,
xscale=None):
    train_scores, val_scores = validation_curve(
        estimator,
        Xtr_pca, y_train,
        param_name=param_name,

```

```
param_range=param_range,
cv=cv_lc,
scoring="roc_auc",
n_jobs=-1
)

train_mean = train_scores.mean(axis=1)
train_std = train_scores.std(axis=1)
val_mean = val_scores.mean(axis=1)
val_std = val_scores.std(axis=1)

plt.figure()
plt.plot(param_range, train_mean, label="Train ROC-AUC")
plt.plot(param_range, val_mean, label="CV ROC-AUC")
plt.fill_between(param_range, train_mean-train_std,
train_mean+train_std, alpha=0.2)
plt.fill_between(param_range, val_mean-val_std, val_mean+val_std,
alpha=0.2)
if xscale is not None:
    plt.xscale(xscale)
plt.xlabel(param_name)
plt.ylabel("ROC-AUC")
plt.title(title)
plt.legend()
plt.show()

# LogisticRegression: curve
lr_for_curve = build_model("LogisticRegression",
best_params["LogisticRegression"])
C_range = np.logspace(-3, 2, 8)
plot_validation_curve(lr_for_curve, "C", C_range, "Validation Curve - LogisticRegression (C)", xscale="log")

# LinearSVM: curve
svm_for_curve = build_model("LinearSVM", best_params["LinearSVM"])
plot_validation_curve(svm_for_curve, "C", C_range, "Validation Curve - LinearSVM (C)", xscale="log")

# DecisionTree: curve
dt_for_curve = build_model("DecisionTree", best_params["DecisionTree"])
depth_range = np.array([1, 2, 3, 5, 8, 12, 16])
plot_validation_curve(dt_for_curve, "max_depth", depth_range, "Validation Curve - DecisionTree (max_depth)")
```

خروجی

```
===== FINAL METRICS (TEST) =====
      model  accuracy  precision   recall      f1  roc_auc
avg_precision
LogisticRegression  0.800284  0.641337 0.564171 0.600284 0.828739
0.606837
LinearSVM  0.719261  0.482871 0.791444 0.599797 0.827882
0.606251
DecisionTree  0.701493  0.465152 0.820856 0.593810 0.787594
0.525024

Saved: final_metrics_after_tuning.csv
<Figure size 640x480 with 0 Axes>
```

- از نظر Accuracy، Precision و ROC AUC تقریبا هم سطح هستند و هر دو واضح از درخت تصمیم بهترند.

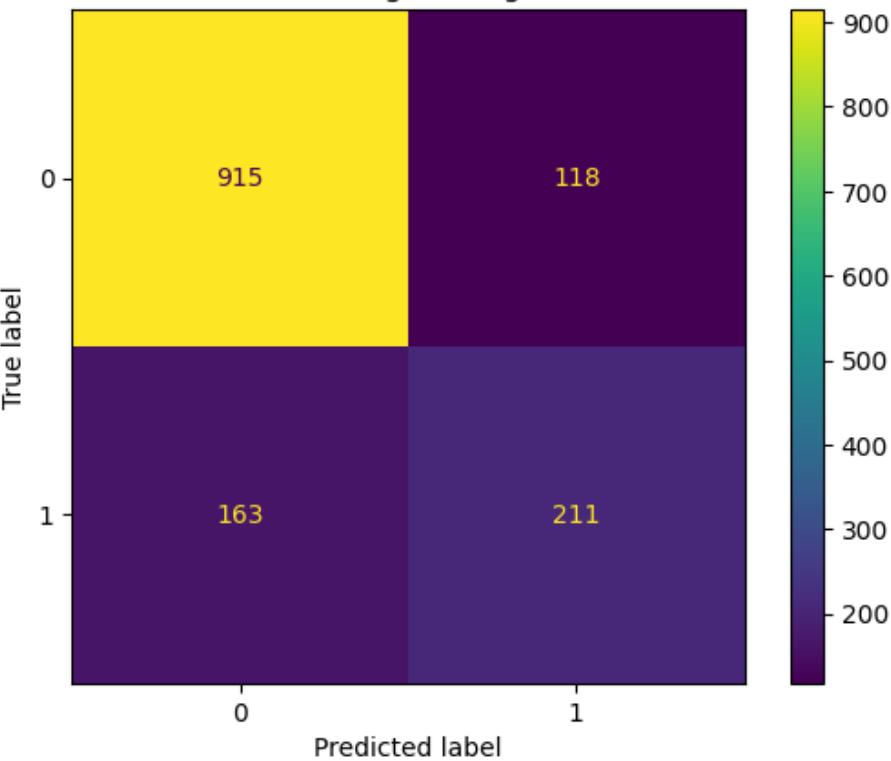
- از نظر Accuracy، لاجستیک بهترین است اما این به معنی بهترین بودن کلی نیست، چون دیتاست نامتوارن است و accuracy به تصمیم آستانه خیلی حساس است.

- از نظر Recall یعنی شکار کردن churn ها درخت و SVM خیلی بهتر از لاجستیک‌اند.
- از نظر Precision یعنی کمتر اشتباه آلام دادن لاجستیک بهتر از دو مدل دیگر است.

اگر هدف این است که تا حد ممکن churn ها از دست نرونده SVM یا درخت بهترند.
اگر هدف این است که کمتر به مشتری‌های غیر churn اشتباه برچسب churn بزنیم لاجستیک بهتر است.

کلاس 1 یعنی Churn و کلاس 0 یعنی Non-Churn

Confusion Matrix - LogisticRegression (Tuned)



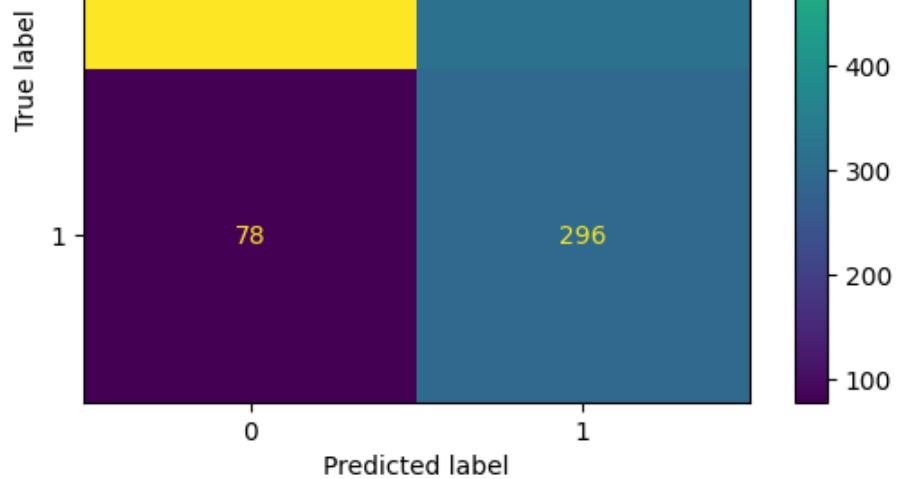
LogisticRegression

FP=118 , TN=915

TP=211 , FN=163

کم دارد (118) یعنی False Positive
به افراد زیادی اشتباه churn نمی‌گوید و
در نتیجه precision بالا می‌رود
زیاد دارد (163) False Negative
یعنی churn های زیادی را از دست
می‌دهد recall پس پایین می‌آید
این مدل محافظه‌کار است، کمتر "هشدار
churn" می‌دهد، برای همین "churn"
واقعی بیشتری را جا می‌اندازد.

Confusion Matrix - LinearSVM (Tuned)



LinearSVM

FP=317 , TN=716

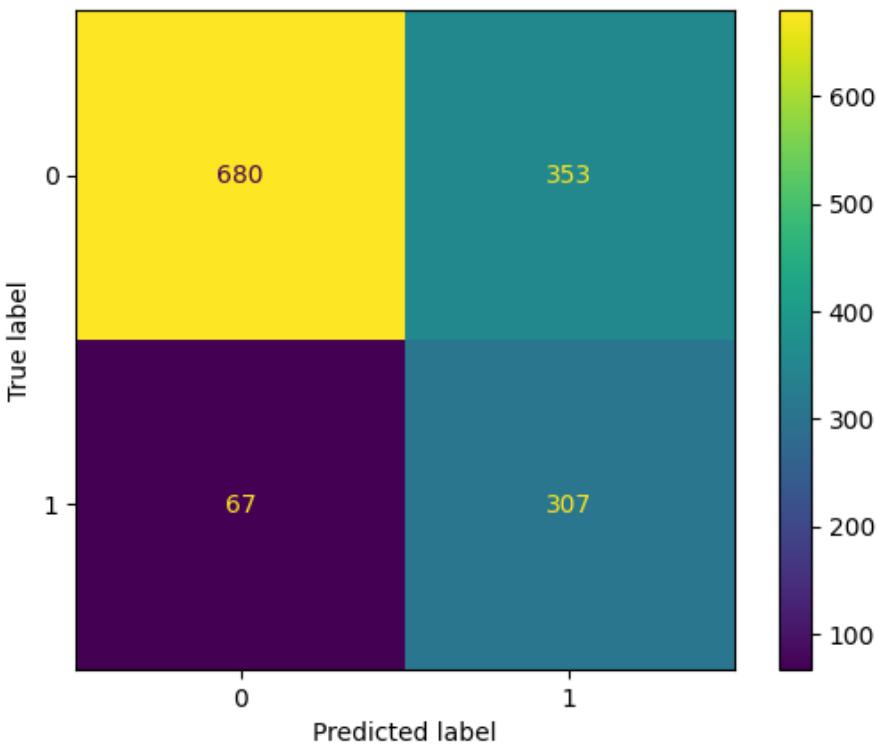
TP=296 , FN=78

زیادتر شده (317) یعنی افراد FP
زیادی را churn اعلام می‌کند و
precision می‌کند

کم شده (78) یعنی FN churn های
کمتری را از دست می‌دهد recall بالا
می‌رود

این مدل تهاجمی‌تر است، زیاد هشدار
mی‌دهد، پس بیشتری را
churn می‌گیرد ولی هزینه هشدار اشتباه بالاتر می‌رود.

Confusion Matrix - DecisionTree (Tuned)



DecisionTree

$FP=353$, $TN=680$

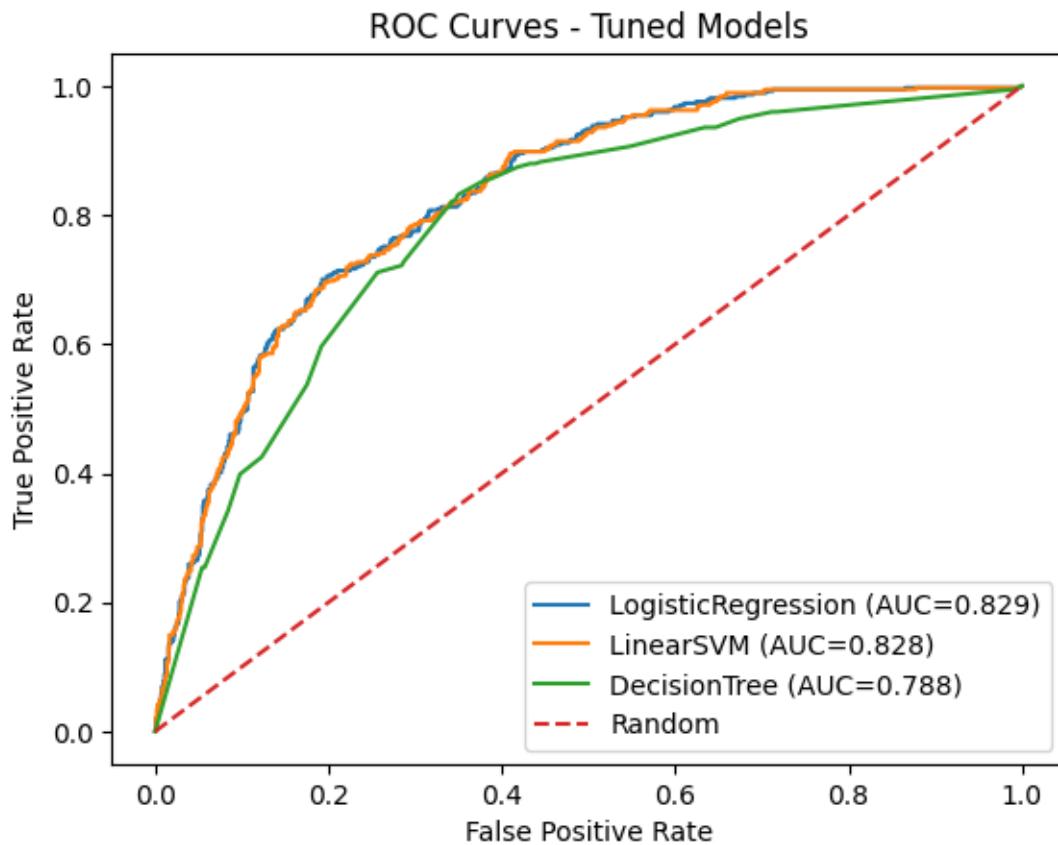
$TP=307$, $FN=67$

بالاترین recall را دارد چون FN کمترین است

اما FP هم زیاد است، یعنی precision پایین می‌ماند

درخت تصمیم خیلی راحت مثبت اعلام می‌کند و churn زیادی را می‌گیرد، ولی مشتری‌های زیادی را اشتباه churn فرض می‌کند.

در دیتاست ما تعداد non-churn بیشتر است. وقتی یک مدل FP را زیاد می‌کند، accuracy سریع افت می‌کند، حتی اگر recall بالا برود. دقیقاً به همین دلیل لاجستیک accuracy بالاتر دارد چون FP خیلی کم دارد و درخت accuracy پایین‌تر دارند چون FP زیاد تولید می‌کنند.



ROC Curve

LogisticRegression AUC ≈ 0.829

LinearSVM AUC ≈ 0.828

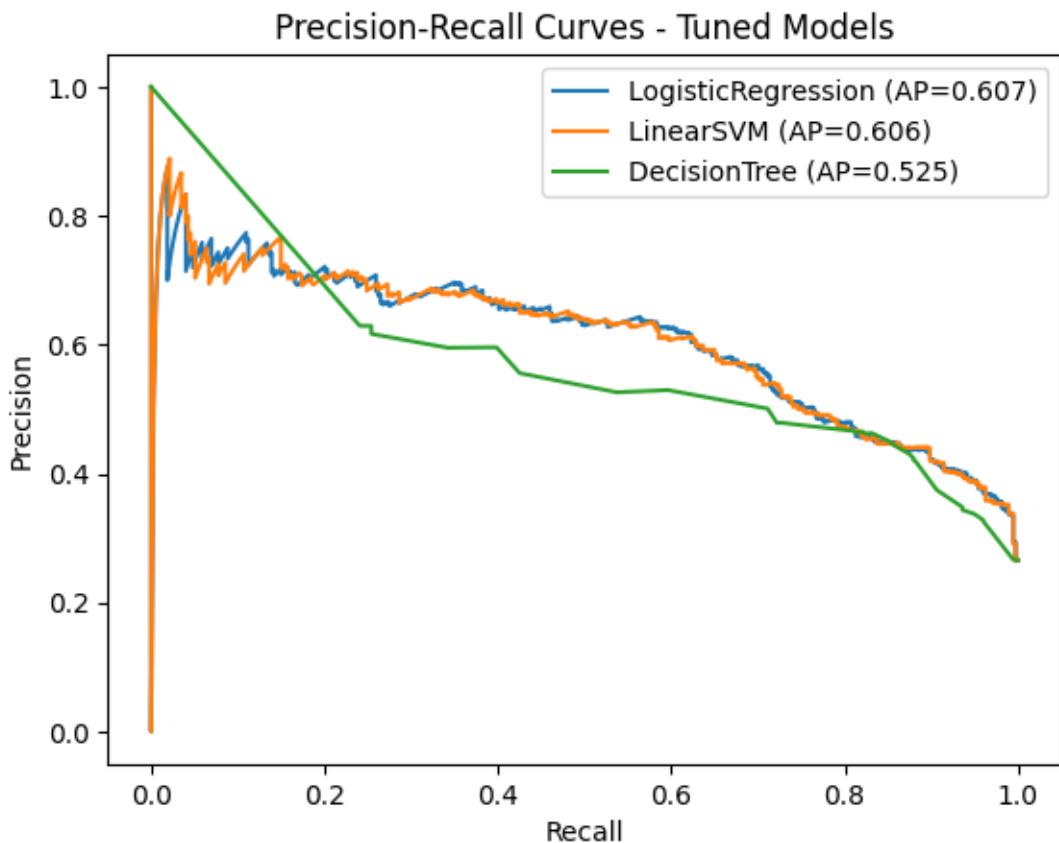
DecisionTree AUC ≈ 0.788

لاجستیک و SVM تقریباً یک توان تفکیک‌پذیری دارند. یعنی اگر آستانه تصمیم را تغییر بدھیم، هر دو می‌توانند trade-off های مشابهی تولید کنند.

درخت تصمیم به طور کلی قدرت رتبه‌بندی و جداسازی ضعیفتری دارد، و این در AUC پایین‌تر مشخص است.

ROC AUC مستقل از آستانه 0.5 است.

این که لاجستیک accuracy بالاتری دارد و SVM recall بالاتر، بیشتر به آستانه تصمیم و شکل خروجی نمره‌ها مربوط است، نه این که یکی ذاتاً خیلی قوی‌تر باشد.



Precision–Recall Curve

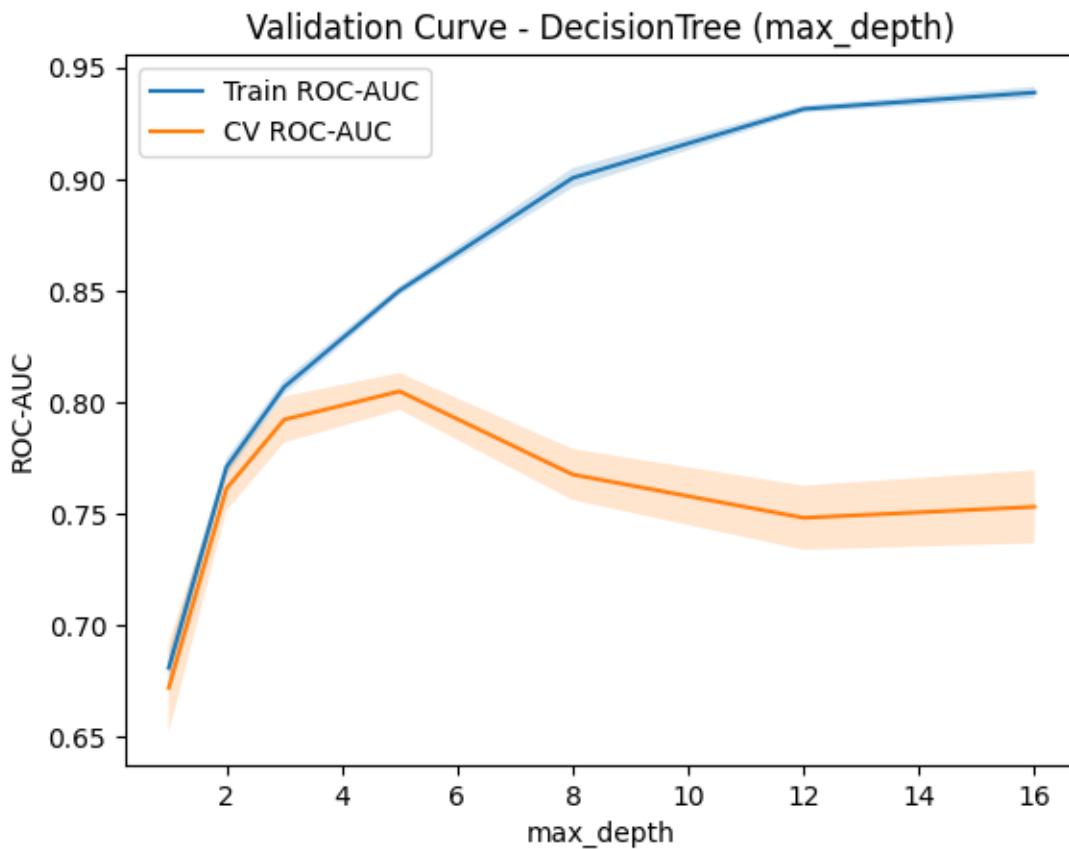
AP لاجستیک ≈ 0.607

AP SVM ≈ 0.606

AP درخت ≈ 0.525

چون کلاس churn اقلیت است، PR curve معمولاً از ROC برای تصمیم‌گیری عملی بهتر است.
باز هم لاجستیک و SVM تقریباً برابرند.

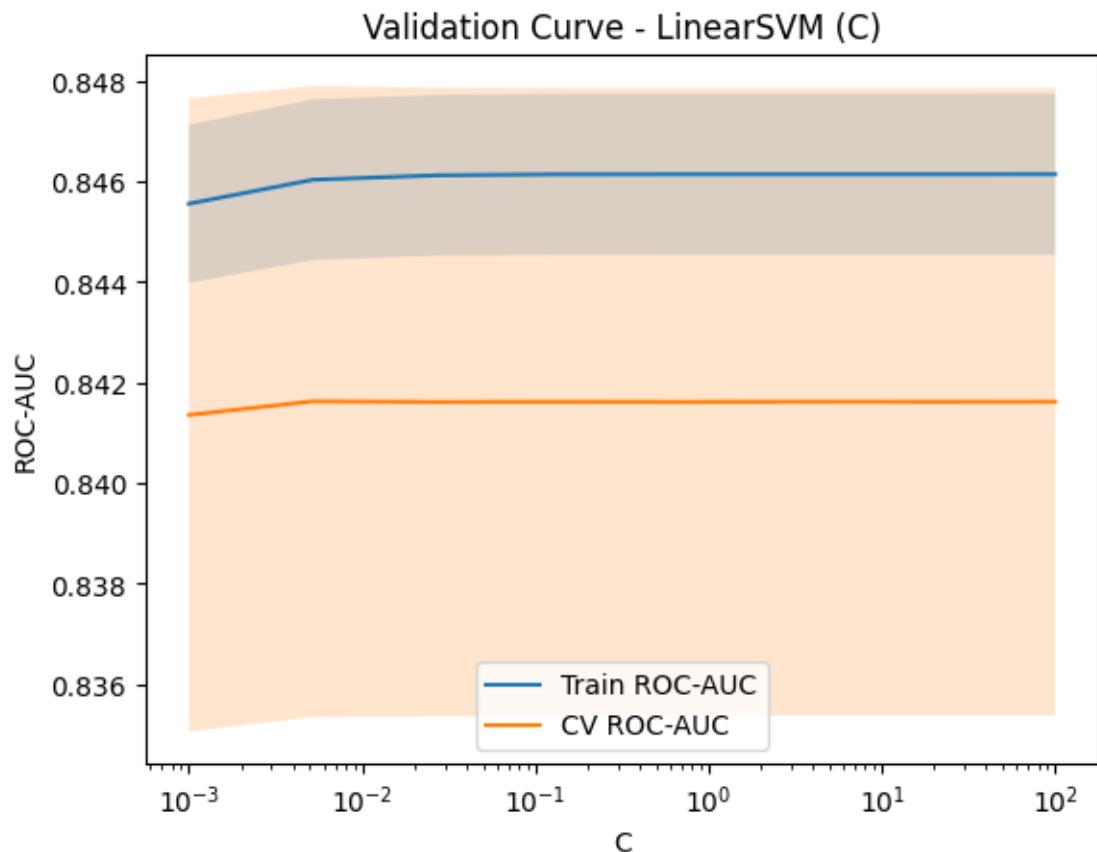
درخت تصمیم پایین‌تر است یعنی وقتی recall را زیاد کنیم، precision سریع‌تر سقوط می‌کند.



درخت تصمیم برحسب `max_depth`

در نمودار ما Train AUC با افزایش `depth` مدام بالا می‌رود overfitting CV AUC تا حدود $5 \approx \text{depth}$ بهتر می‌شود و بعد افت می‌کند این دقیقاً تعريف کلاسیک است:

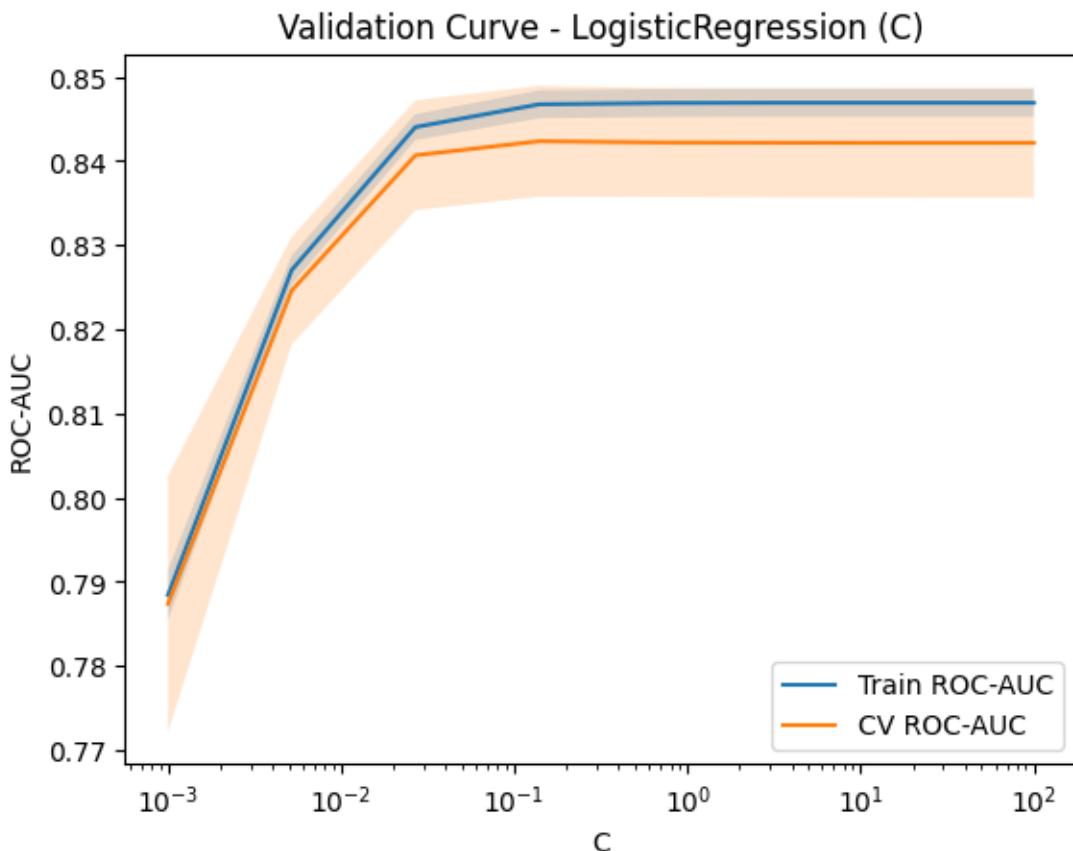
عمق زیاد باعث می‌شود مدل جزئیات و نویز را حفظ کند و train عالی شود ولی روی داده جدید بدتر می‌شود و CV افت می‌کند پس انتخاب `depth=5` کاملاً منطقی است و نمودار آن را تایید می‌کند.



C بر حسب LinearSVM

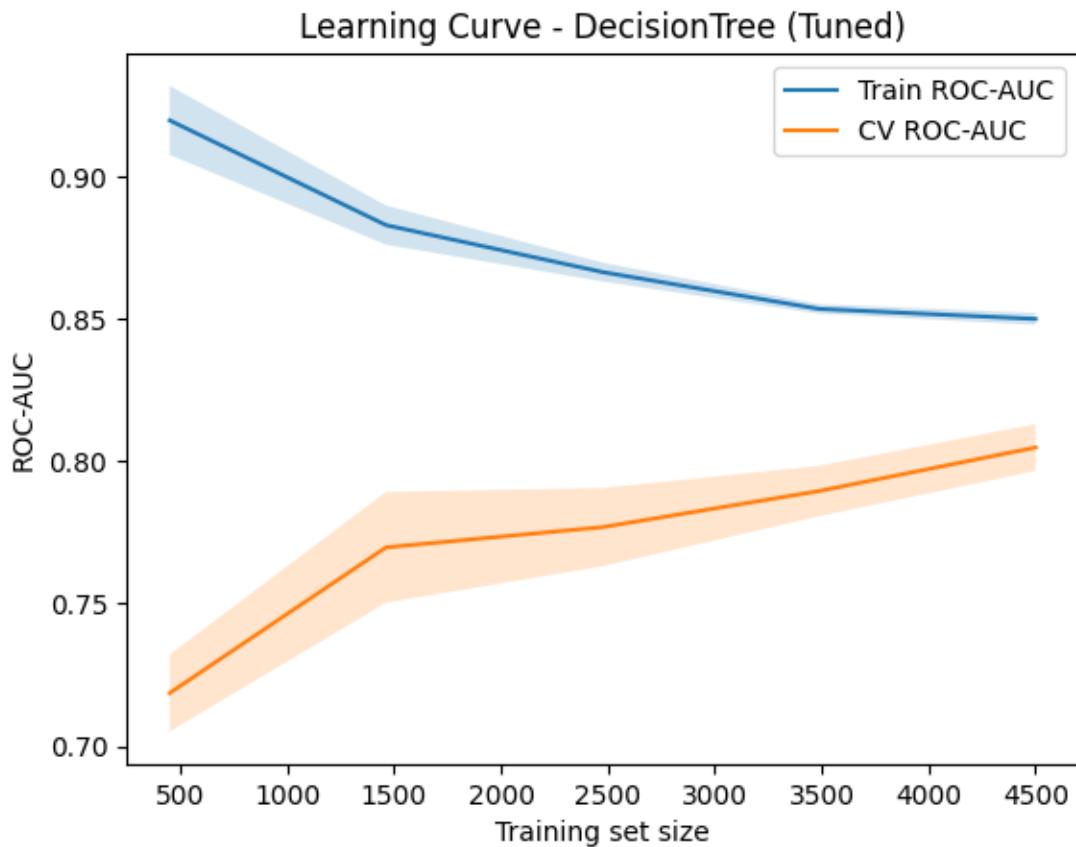
منحنی تقریباً تخت است یعنی عملکرد مدل نسبت به C در این بازه خیلی حساس نیست این معمولاً به این معناست یا داده بعد از پیش‌پردازش خیلی خوب جدا می‌شود یا ناحیه بهینه پهن است و چند مقدار C نزدیک به هم جواب مشابه می‌دهند

این با خروجی تیونینگ هم جور است که Grid و Random و Optuna همگی CV نزدیک به هم داده‌اند.



C بر حسب LogisticRegression

نمودار به ما نشان می‌دهد در C خیلی کوچک مدل underfit است و CV AUC پایین‌تر است. با افزایش C عملکرد بهتر می‌شود و بعد به یک plateau می‌رسد یعنی بعد از یک نقطه، کاهش regularization دیگر سودی ندارد و مدل به سقف توان خودش روی این ویژگی‌ها می‌رسد.



DecisionTree

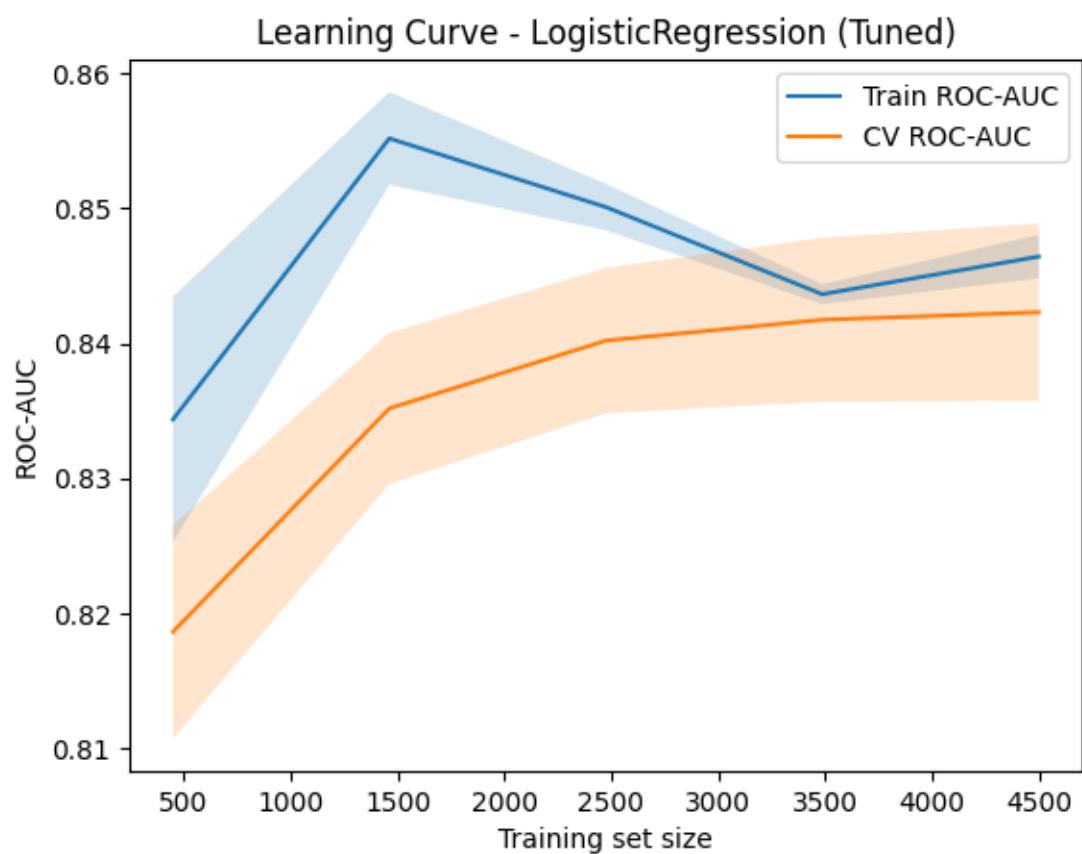
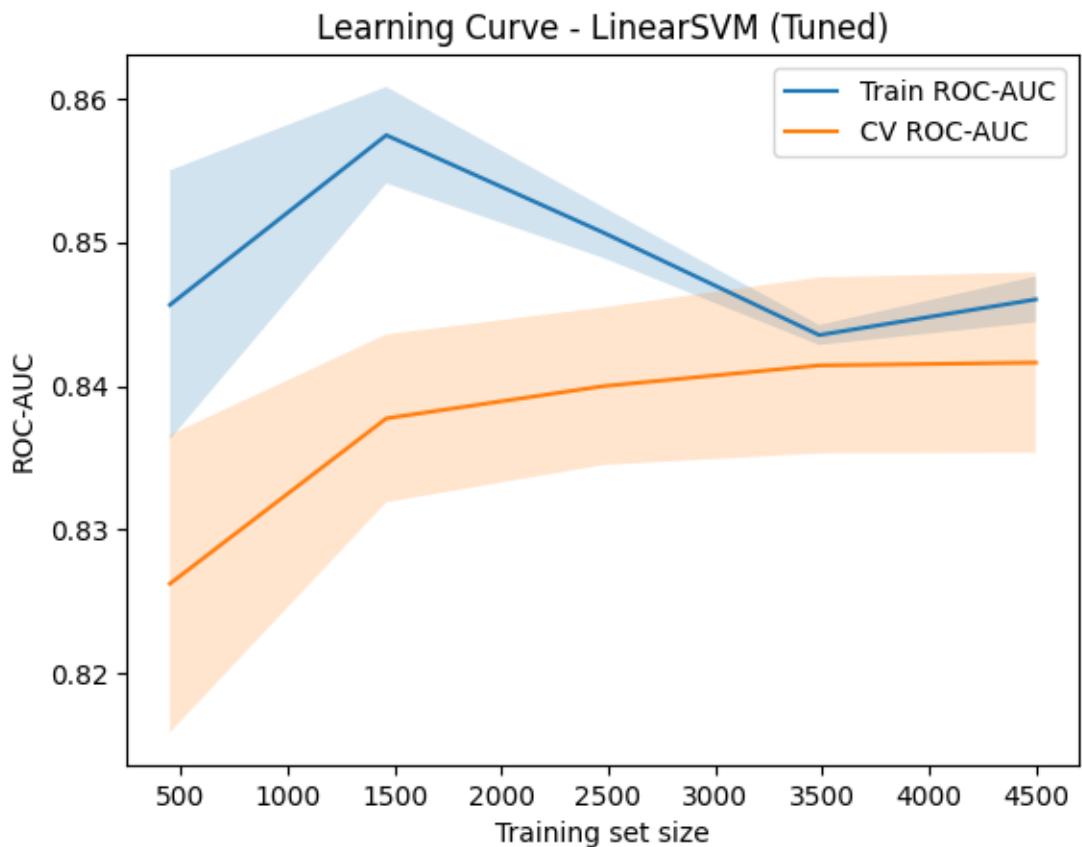
در نمودار Train AUC بالا شروع می‌شود و با داده بیشتر پایین می‌آید. CV AUC با داده بیشتر بالا می‌رود و فاصله Train و CV زیاد می‌ماند

این یعنی variance بالا و مدل هنوز overfit است. داده بیشتر کمک می‌کند ولی مشکل را کامل حل نمی‌کند.

برای حل این مشکل می‌توانیم راه حل‌های زیر را انجام دهیم.

برای محدود کردن بیشتر پیچیدگی: `min_samples_leaf`, `max_depth` کمتر، `min_samples_split` بیشتر

یا رفتن به سمت ensemble ها مثل Gradient Boosting یا RandomForest که درخت را کنترل می‌کنند



LogisticRegression و LinearSVM

هر دو CV AUC با داده بیشتر بهتر می‌شود و بعد آرام آرام نزدیک سقف می‌شود فاصله train و CV خیلی بزرگ نیست این یعنی generalization بهتر از درخت است و مدل‌ها پایدارترند. همچنین نشان می‌دهد که توان مدل تا حد خوبی استفاده شده و اگر improvement بخواهیم، معمولاً باید: ویژگی‌ها بهتر شوند یا مدل غیرخطی‌تر و قوی‌تر بباید نه صرفاً تغییر جزئی یک هایپرپارامتر

دلایل بهتر شدن لاجستیک و SVM نسبت به درخت تصمیمیم

- ماهیت داده و ویژگی‌ها

داده بعد از scaling و one-hot و مخصوصاً بعد از PCA، خیلی مناسب مدل‌های خطی است. دقیقاً برای همین نوع فضاهای عالی‌اند.

- درخت تصمیمیم مستعد overfitting است

حتی با تیونینگ، درخت منفرد معمولاً variance بالاتری دارد و learning curve دقیقاً این را نشان می‌دهد.

- اثر PCA روی درخت

ویژگی‌ها را به ترکیب‌های خطی پیوسته تبدیل می‌کند. درخت تصمیمیم split های PCA محورهای مراستا می‌زند و در چنین فضاهایی معمولاً به قدرت مدل‌های خطی نمی‌رسد، مگر با تنظیمات ensemble دقیق یا با

به طور کلی

- اگر معیار اصلی PR AUC یا ROC AUC باشد ← لاجستیک و SVM تقریباً برابرند و هر دو بهتر از درخت‌اند.

- اگر هدف کم کردن هشدار اشتباه باشد ← LogisticRegression خیلی کمتر دارد.

- اگر هدف گرفتن churn بیشتر باشد ← DecisionTree یا LinearSVM بهترند چون recall بالاتر دارند.

اگر بخواهیم یک انتخاب متعادل و صنعتی تر داشته باشیم:

- معمولاً لاجستیک به خاطر پایداری، سادگی، تفسیرپذیری و precision بهتر انتخاب پیشفرض است بعد آستانه تصمیم را بر اساس هزینه کسبوکار تنظیم می‌کند تا recall هم بالا بیاید مدل درخت تصمیم نشانه بیش برازش داشت اما با تیونینگ آن را کنترل کردیم.
- دقیقاً الگوی کلاسیک بیش برازش است.

با زیاد شدن عمق، Train ROC-AUC مدام بالا می‌رود (تا حوالی 0.93–0.94). ولی CV بعد از یک نقطه حدود depth≈5 بهترین می‌شود و بعد آن افت می‌کند تا حدود 0.75.

این یعنی درخت وقتی عمیق می‌شود، روی داده‌ی Train خیلی خوب حفظ می‌کند ولی روی داده‌ی جدید Overfitting (بدتر عمل می‌کند یعنی Validation/CV)

آیا مدل نهایی درخت تصمیم هنوز overfit است؟

ما بهترین پارامترها را طوری انتخاب کردیم که درخت محدود بشود مثلاً $\text{max_depth}=5$ و $\text{min_samples_split}=\text{min_samples_leaf}$ بزرگ‌تر با این کار، درخت‌های عمیق کنترل شده. اما درخت تیون شده هنوز یک فاصله‌ی قابل توجه بین Train و CV نشان می‌دهد:

Train ROC-AUC 0.85 به بالا) همچنان بالاتر می‌ماند (حدود

CV ROC-AUC 0.80 به بالا) پایین‌تر است و با داده بیشتر آرام آرام بالا می‌رود (حدود

در نتیجه هنوز کمی بیش برازش وجود دارد (ذات درخت تصمیم هم همین است)، ولی نسبت به حالت‌های عمیق‌تر خیلی بهتر و قابل قبول‌تر شده است.

فصل 11- نتیجه گیری

در این پژوهه هدف اصلی پیش بینی ریزش مشتری در دیتاست Telco Customer Churn بود. روند کار از مرحله آماده سازی داده تا انتخاب مدل نهایی و تحلیل رفتاری مدل ها به صورت گام به گام انجام شد تا هم دقت نتایج قابل اتكا باشد و هم امکان تکرارپذیری کامل فراهم شود.

در ابتدا داده ها پاکسازی شدند. ستون شناسه مشتری حذف شد چون اطلاعات پیش بینی کننده نداشت. ستون TotalCharges که در برخی ردیف ها مقدار خالی داشت به عددی تبدیل شد و ردیف های دارای مقدار نامعتبر حذف شدند. همچنین SeniorCitizen به صورت دسته ای در نظر گرفته شد تا به شکل درست در مرحله کدگذاری وارد مدل شود. سپس برچسب هدف Churn به صورت دودویی صفر و یک تبدیل شد.

برای جلوگیری از سوگیری در ارزیابی، داده ها به صورت Train و Test با نسبت 80 به 20 تقسیم شدند و از استفاده شد تا نسبت کلاس ها در هر دو بخش مشابه باقی بماند. این موضوع در مسئله ریزش بسیار مهم است چون معمولاً تعداد مشتریان غیر ریزشی بیشتر است و اگر نسبت کلاس ها حفظ نشود، معیارهایی مثل Accuracy می تواند تصویر اشتباه بدهد. علاوه بر این، برای ارزیابی منصفانه در مرحله تیونینگ از Stratified K-Fold با 5 فولد استفاده شد تا در هر فولد نیز همان نسبت کلاس ها حفظ شود و نوسان نتایج کمتر شود. در تمام قسمت های تصادفی سازی نیز random_state برابر 42 تنظیم شد تا نتایج کاملاً تکرارپذیر باشند.

پس از آماده سازی داده، ویژگی های دسته ای با One Hot Encoding به ویژگی های عددی تبدیل شدند و ویژگی ها نرمال سازی شدند. سپس برای کنترل ابعاد بالا و کاهش هم خطی و افزایش سرعت آموزش، کاهش بُعد با PCA انجام شد. نتیجه PCA این بود که تعداد ویژگی ها بعد از کاهش بُعد به 20 مؤلفه رسید که نشان می دهد بخش زیادی از اطلاعات در تعداد کمی مؤلفه فشرده شده است و این کار هم به ساده تر شدن مدل ها کمک می کند و هم احتمال بیش برآش را کاهش می دهد.

در ادامه سه مدل اصلی انتخاب و مقایسه شدند Decision Tree، RandomizedSearchCV و GridSearchCV. برای هر سه مدل، تیونینگ ابرپارامترها با سه روش انجام شد. برای بهینه سازی هم ROC AUC و Optuna و معيار بهينه سازی هم CV نشان داد اختلاف بين سه روش جستجو خيلي کم است. دليلش اين است که فضای جستجو محدود و نسبتاً ساده بوده و مدل ها سريع به ناحيه نزديک به بهينه می رسند، بنابراین Grid و Random Optuna تقریباً به پاسخ يکسان می رسند.

اگر هدف پروژه انتخاب مدلی با بهترین عملکرد کلی و تعادل مناسب بین معیارها باشد، Logistic Regression بهترین گزینه است چون بالاترین ROC AUC و Precision را دارد و از نظر پایداری هم در نمودارها رفتار قابل اتکاگری نشان می دهد.

اگر هدف کسب و کار این باشد که حتی الامکان مشتری ریزشی از دست نرود و هزینه تماس یا پیشنهاد اشتباه پایین باشد، Linear SVM انتخاب مناسب تری است چون Recall بسیار بالاتری دارد و مشتریان ریزشی بیشتری را شناسایی می کند، هرچند باید پذیرفت که خطای مثبت کاذب بالا می رود.

در این پروژه به دلیل نشانه های واضح بیش برآش و ROC AUC Decision Tree پایین تر نسبت به دو مدل دیگر، گزینه نهایی توصیه شده نیست. همچنین ترکیب PCA با درخت تصمیم معمولاً به اندازه مدل های خطی سودمند نیست چون PCA ساختار ویژگی ها را به مؤلفه های خطی تبدیل می کند و ممکن است برخی تعامل های قابل استفاده برای درخت را کم رنگ کند.